

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ THÔNG TIN

Đề tài

**XÂY DỰNG HỆ THỐNG TƯ VẤN
TUYỂN SINH THÔNG MINH DỰA TRÊN
MÔ HÌNH HỘI THOẠI TỰ ĐỘNG**

**BUILDING A SMART ENROLLMENT
ADVISORY SYSTEM BASED ON AN
AUTOMATIC DIALOGUE MODEL**

Sinh viên thực hiện Nguyễn Minh Thiện
Mã số: B2111822
Khoá: K47

Cần Thơ, 08/2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN



LUẬN VĂN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ THÔNG TIN

Đề tài

XÂY DỰNG HỆ THỐNG TƯ VẤN
TUYỂN SINH THÔNG MINH DỰA TRÊN
MÔ HÌNH HỘI THOẠI TỰ ĐỘNG

BUILDING A SMART ENROLLMENT
ADVISORY SYSTEM BASED ON AN
AUTOMATIC DIALOGUE MODEL

Giảng viên hướng dẫn:
PGS. TS. GVCC. Phạm Nguyên Khang

Sinh viên thực hiện:
Nguyễn Minh Thiện
Mã số: B2111822
Khoá: K47

Cần Thơ, 08/2025

XÁC NHẬN CHỈNH SỬA LUẬN VĂN THEO YÊU CẦU CỦA HỘI ĐỒNG

Tên luận văn (tiếng Việt và tiếng Anh):

**Xây dựng hệ thống tư vấn tuyển sinh thông minh dựa trên mô hình hội
thoại tự động**

**Building a smart enrollment advisory system based on an automatic di-
alogue model**

Họ tên sinh viên: **Nguyễn Minh Thiện**

MASV: **B2111822**

Mã lớp: **DI21V7A1**

Đã báo cáo tại hội đồng ngành: **Công nghệ thông tin**

Ngày báo cáo: **13/08/2025**

Luận văn đã được chỉnh sửa theo góp ý của Hội đồng.

Cần Thơ, ngày ... tháng ... năm 20...

Giáo viên hướng dẫn

(Ký và ghi rõ họ tên)

LỜI CẢM ƠN

Báo cáo này không thể hoàn thiện nếu như không có sự hỗ trợ, hướng dẫn và những góp ý từ PGS. TS. GVCC. Phạm Nguyên Khang. Em xin gửi lời cảm ơn chân thành đến Thầy, sự hướng dẫn và góp ý từ Thầy là vô cùng quý báu giúp em có thể hoàn thành được quyển luận văn này. Ngoài ra em cũng muốn tỏ lòng biết ơn đến TS. Lâm Nhựt Khang, người đã tận tình hướng dẫn và giúp em định hướng từ những giai đoạn đầu tiên.

Em cũng xin tỏ lòng biết ơn đến các Thầy Cô của Trường Công nghệ thông tin & Truyền thông, Đại học Cần Thơ đã giúp em trang bị những kiến thức cần thiết và quý báu trong suốt khoảng thời gian học tập trường.

Sự quan tâm và hỗ trợ từ gia đình cũng là một nguồn động lực to lớn giúp em hoàn thành được quyển luận văn này. Cảm ơn gia đình, các anh chị bạn bè đã đồng hành trong suốt khoảng thời gian vừa qua.

Trong quá trình nghiên cứu và hoàn thiện luận văn, mặc dù đã cố gắng để tránh các sai sót và cố gắng hoàn thiện luận văn một cách chu đáo nhất có thể, tuy nhiên vẫn khó tránh khỏi các thiếu sót ngoài mong muốn. Kính mong nhận được nhận xét và góp ý từ các Thầy Cô để luận văn này được hoàn thiện hơn.

Em xin chân thành cảm ơn!

Cần Thơ, ngày 04 tháng 08 năm 2025

Sinh viên thực hiện

Nguyễn Minh Thiện

TÓM TẮT

Trong bối cảnh tuyển sinh đại học ngày càng cạnh tranh, việc tiếp cận thông tin chính xác và kịp thời là một thách thức lớn đối với cả thí sinh và các cơ sở giáo dục. Luận văn này trình bày quá trình nghiên cứu và xây dựng "Hệ thống Tư vấn Tuyển sinh Thông minh" cho Đại học Cần Thơ, dựa trên mô hình hội thoại tự động nhằm giải quyết vấn đề này.

Mục tiêu chính của đề tài là phát triển một chatbot có khả năng cung cấp thông tin tuyển sinh năm 2025 một cách chính xác, đáng tin cậy và tức thì. Hệ thống được xây dựng dựa trên kỹ thuật Retrieval-Augmented Generation (RAG), kết hợp sức mạnh của các mô hình ngôn ngữ lớn với một cơ sở tri thức chuyên biệt được trích xuất từ các nguồn dữ liệu chính thức của nhà trường như đề án tuyển sinh, các quy định, quy chế và thông báo.

Luận văn mô tả chi tiết quy trình thực hiện, bao gồm các giai đoạn: thu thập và tiền xử lý dữ liệu từ các nguồn và định dạng khác nhau, xây dựng hệ thống truy xuất thông tin hiệu quả bằng cách áp dụng các kỹ thuật tối ưu như mở rộng truy vấn và tái xếp hạng và sau đó sinh câu trả lời dựa trên các thông tin truy xuất được với một mô hình ngôn ngữ lớn.

Để đánh giá hiệu quả, hệ thống được thực nghiệm trên hai bộ dữ liệu: một bộ được tổng hợp (*Synthesized*) và một bộ được thu thập từ các cuộc hội thoại thực tế (*Collected*). Thành phần truy xuất được đánh giá bằng các chỉ số tiêu chuẩn như Recall@k, MRR@k, MAP@k, và NDCG@k. Thành phần phản hồi được đánh giá dựa trên bộ tiêu chí của framework RAGAS, bao gồm Faithfulness (tính trung thực), Answer Relevance (sự liên quan của câu trả lời) và Context Relevance (sự liên quan của ngữ cảnh).

Kết quả thực nghiệm cho thấy việc áp dụng kết hợp các kỹ thuật mở rộng truy vấn và tái xếp hạng giúp cải thiện đáng kể hiệu suất của hệ thống so với phương pháp cơ bản giúp nâng cao độ chính xác và mức độ liên quan của thông tin được cung cấp. Cụ thể đạt được các kết quả tốt nhất cho thành phần truy xuất là 0.7713 trên Recall@10, 0.7008 trên MRR@10, 0.6906 trên MAP@10 và 0.7133 trên NDCG@10. Về phần phản hồi của toàn hệ thống, đạt được các kết quả tốt nhất trên tập *Synthesized* với 0.9060 trên Context Relevance, 0.7923 trên Faithfulness và 0.7518 trên Answer Relevance cho thấy độ hiệu quả và tin cậy của hệ thống.

ABSTRACT

In the increasingly competitive landscape of university admissions, accessing accurate and timely information poses a significant challenge for both applicants and educational institutions. This thesis presents the research and development of an "Smart Enrollment Advisory System" for Can Tho University, leveraging an automated dialogue model to address this issue.

The primary objective of this study is to develop a chatbot capable of delivering precise, reliable, and instantaneous admissions information for the year 2025. The system is built using the Retrieval-Augmented Generation (RAG) technique, which integrates the capabilities of large language models with a specialized knowledge base derived from official university sources, including admissions guidelines, regulations, policies, and announcements.

The thesis outlines the implementation process in detail, encompassing the following stages: data collection and preprocessing from diverse sources and formats, development of an efficient information retrieval system through optimization techniques such as query expansion and re-ranking, and response generation based on retrieved information using a large language model.

To assess the system's performance, experiments were conducted on two datasets: one synthesized (*Synthesized*) and one gathered from real-world conversations (*Collected*). The retrieval component was evaluated using standard metrics, including Recall@k, MRR@k, MAP@k, and NDCG@k. The response generation component was assessed based on the RAGAS framework, with criteria such as Faithfulness, Answer Relevance, and Context Relevance.

Experimental results demonstrate that the integration of query expansion and re-ranking techniques significantly enhances the system's performance compared to baseline approaches, improving both the accuracy and relevance of the provided information. Specifically, the retrieval component achieved its best results with 0.7713 on Recall@10, 0.7008 on MRR@10, 0.6906 on MAP@10, and 0.7133 on NDCG@10. For the overall system response, the highest scores on the *Synthesized* dataset were 0.9060 on Context Relevance, 0.7923 on Faithfulness, and 0.7518 on Answer Relevance, underscoring the system's effectiveness and reliability.

LỜI CAM ĐOAN

Tôi xin cam đoan luận văn tốt nghiệp với đề tài "Xây dựng hệ thống tư vấn tuyển sinh thông minh dựa trên mô hình hội thoại tự động" là công trình nghiên cứu của chúng tôi, được thực hiện dưới sự theo dõi và hướng dẫn từ PGS. TS. GVCC. Phạm Nguyên Khang. Ngoài các thông tin, số liệu đã được trích dẫn nguồn đầy đủ thì các kết quả trong luận văn này là trung thực và là kết quả của quá trình nghiên cứu và thực nghiệm của chúng tôi. Nếu không đúng như những điều đã nêu, chúng tôi xin hoàn toàn chịu trách nhiệm đối với đề tài của mình.

Cần Thơ, ngày 04 tháng 08 năm 2025

Người cam đoan

Nguyễn Minh Thiện

DANH MỤC TỪ VIẾT TẮT

AI Artificial Intelligence

DCG Discounted Cumulative Gain

DPR Dense Passage Retrieval

LLM Large Language Model

MAP Mean Average Precision

MRR Mean Reciprocal Rank

NDCG Normalized Discounted Cumulative Gain

OCR Optical Character Recognition

PLM Pre-trained Language Model

RAG Retrieval-Augmented Generation

RRF Reciprocal Rank Fusion

MỤC LỤC

LỜI CẢM ƠN	iii
TÓM TẮT	v
ABSTRACT	vii
LỜI CAM ĐOAN	ix
DANH MỤC TỪ VIẾT TẮT	xi
DANH MỤC HÌNH ẢNH	xv
DANH MỤC BẢNG BIỂU	xvii
1 GIỚI THIỆU TỔNG QUAN	1
1.1 Đặt vấn đề	1
1.2 Mục tiêu của đề tài	1
1.3 Các nghiên cứu liên quan	2
1.4 Đối tượng và Phạm vi nghiên cứu	3
1.5 Phương pháp nghiên cứu	3
1.6 Cấu trúc luận văn	4
2 CƠ SỞ LÝ THUYẾT	5
2.1 Kiến trúc Transformer	5
2.1.1 Cơ chế tự chú ý	6
2.1.2 Chú ý đa đầu	6
2.1.3 Mạng truyền thẳng	6
2.1.4 Chuẩn hoá theo tầng	7
2.1.5 Kiến trúc mô hình	7
2.2 Từ kiến trúc Transformer đến các mô hình ngôn ngữ lớn hiện đại . . .	7
2.3 Hệ thống hỏi đáp	8
2.4 Retrieval-Augmented Generation	9
2.4.1 Nguồn gốc và sự phát triển	10
2.4.2 Các thành phần chính của hệ thống RAG	10
2.4.3 Một số kỹ thuật tối ưu RAG	11
2.5 Truy xuất thưa, truy xuất dày đặc và truy xuất hỗn hợp	11
2.5.1 Truy xuất thưa	12
2.5.2 Truy xuất dày đặc	13
2.5.3 Truy xuất hỗn hợp	13
2.6 Các phương pháp đánh giá hệ thống RAG	13
2.6.1 Recall@k	14
2.6.2 Mean Reciprocal Rank - MRR@k	14

2.6.3	Mean Average Precision - MAP@k	14
2.6.4	Discounted Cumulative Gain - DCG@k và Normalized Discounted Cumulative Gain - NDCG@k	15
2.6.5	Faithfulness, Answer relevance và Context relevance	15
3	PHƯƠNG PHÁP THỰC HIỆN	17
3.1	Nguồn dữ liệu	17
3.2	Tiền xử lý dữ liệu cho RAG	17
3.3	Truy xuất thông tin cho hệ thống RAG	22
3.3.1	Query expansion	23
3.3.2	Reranking	25
3.4	Sinh câu trả lời với mô hình ngôn ngữ lớn	26
4	THỰC NGHIỆM	27
4.1	Môi trường thực nghiệm	27
4.2	Dữ liệu thực nghiệm	27
4.2.1	Dữ liệu tổng hợp	27
4.2.2	Dữ liệu thu thập	28
4.3	Kết quả đánh giá thành phần truy xuất	28
4.4	Kết quả đánh giá phần phản hồi	30
4.5	Đánh giá về thời gian phản hồi của hệ thống	31
4.6	Thảo luận	32
5	KẾT LUẬN VÀ ĐỀ XUẤT HƯỚNG PHÁT TRIỂN	33
5.1	Kết luận	33
5.2	Đề xuất hướng phát triển	33
PHỤ LỤC		39
A	Các prompt templates được sử dụng	39
A.1	Prompt cho phần chatbot	39
A.2	Prompt cho phần Query expansion	40
A.3	Prompt cho phần mô tả nội dung của bảng	41
A.4	Prompt cho phần trích xuất công thức toán từ ảnh	41
A.5	Prompt cho phần tổng hợp câu hỏi từ các tài liệu	42
A.6	Prompt cho phần trích xuất câu hỏi từ đoạn tin nhắn	43

DANH MỤC HÌNH ẢNH

2.1	Minh hoạ kiến trúc của mô hình Transformer [21].	5
3.1	Sơ đồ tổng quan về quy trình thu thập và xử lý dữ liệu	18
3.2	Ví dụ quá trình chia nhỏ dữ liệu dựa trên header thành các section, chia nhỏ các section thành các chunk và nối thêm các header để tăng thêm ngữ cảnh cho các chunk	20
3.3	ví dụ minh hoạ quá trình mô tả nội dung của bảng	21
3.4	Minh hoạ quá trình chuyển các công thức ở dạng ảnh sang L ^A T _E X bằng OCR với <i>Gemini 2.5 Flash</i>	22
3.5	Toàn bộ quy trình xử lý câu hỏi từ người dùng và đưa ra phản hồi của hệ thống	23
3.6	Minh hoạ việc tổng hợp các tài liệu khi thực hiện truy xuất trên nhiều truy vấn với thuật toán <i>Reciprocal rank fusion</i>	25
4.1	Biểu đồ so sánh kết quả trên các chỉ số đánh giá thành phần truy xuất đối với các giá trị k khác nhau của phương pháp Query expansion + Reranking	31

DANH MỤC BẢNG BIỂU

3.1	Thông tin về số lượng dữ liệu cho từng định dạng HTML và PDF được thu thập trong nghiên cứu cùng với số lượng section và chunk sau khi tiền xử lý dữ liệu	19
3.2	Thống kê số lượng header và độ dài header trong các chunk dữ liệu . .	22
3.3	Một số ví dụ về các câu hỏi liên quan được tạo ra dựa trên câu hỏi gốc cho kỹ thuật Query expansion	24
4.1	Chi tiết về các tập dữ liệu cho phần thực nghiệm	27
4.2	Một số ví dụ về các câu hỏi tổng hợp được của tập dữ liệu <i>Collected</i> . .	28
4.3	Kết quả đánh giá Recall của thành phần truy xuất	29
4.4	Kết quả đánh giá MRR của thành phần truy xuất	29
4.5	Kết quả đánh giá MAP của thành phần truy xuất	29
4.6	Kết quả đánh giá NDCG của thành phần truy xuất	29
4.7	Kết quả đánh giá trên phản hồi của hệ thống với RAGAS	30
4.8	Kết quả đánh giá về thời gian phản hồi của hệ thống với $k = 10$. Các kết quả được thể hiện ở dạng $\text{mean} \pm \text{std}$ với mean là giá trị trung bình và std là độ lệch chuẩn	32

CHƯƠNG 1

GIỚI THIỆU TỔNG QUAN

1.1 Đặt vấn đề

Trong bối cảnh cuộc cách mạng công nghiệp 4.0 đang diễn ra mạnh mẽ, giáo dục đại học Việt Nam đứng trước những cơ hội và thách thức lớn, đặc biệt là trong công tác tuyển sinh. Hàng năm, quá trình tuyển sinh đại học thu hút sự quan tâm của hàng triệu thí sinh và phụ huynh trên cả nước. Đây là giai đoạn cao điểm và đầy áp lực không chỉ cho thí sinh mà còn cho các cơ sở giáo dục đại học.

Về phía thí sinh và phụ huynh, một trong những khó khăn lớn nhất là việc phải đối mặt với một ma trận thông tin. Với hàng loạt các phương thức xét tuyển, tổ hợp môn thi, thông tin về ngành học, việc tìm kiếm và tổng hợp thông tin chính xác, đầy đủ và kịp thời dần trở nên phức tạp. Về phía các trường đại học, công tác tuyển sinh cũng đối mặt với nhiều thách thức. Đội ngũ cán bộ tư vấn thường xuyên bị quá tải. Việc tư vấn chủ yếu bị giới hạn trong giờ hành chính, trong khi nhu cầu tìm hiểu thông tin của thí sinh lại diễn ra 24/7.

Để giải quyết những vấn đề trên, việc ứng dụng công nghệ, đặc biệt là trí tuệ nhân tạo (AI) và các hệ thống hội thoại tự động (chatbot), vào công tác tư vấn tuyển sinh đang trở thành một xu hướng tất yếu. Thực tế cho thấy, nhiều trường đại học trong nước cũng đã bắt đầu triển khai các hệ thống chatbot AI để hỗ trợ thí sinh, cung cấp thông tin nhanh chóng và liên tục [1; 2; 3]. Các hệ thống này không chỉ giúp giải đáp thắc mắc tức thì mà còn có khả năng cá nhân hóa trải nghiệm người dùng, gợi ý ngành học phù hợp dựa trên năng lực và sở thích.

Sự phát triển vượt bậc của các mô hình ngôn ngữ lớn (Large Language Models - LLMs) như GPT [4], Gemini [5], Grok [6; 7], Claude [8; 9] kết hợp với kỹ thuật Retrieval-Augmented Generation (hay RAG) [10; 11; 12; 13], mở ra một tiềm năng to lớn để xây dựng các hệ thống tư vấn tuyển sinh thông minh và hiệu quả. Kỹ thuật RAG kết hợp các mô hình ngôn ngữ lớn với việc truy xuất thông tin từ một cơ sở kiến thức chuyên biệt và được cập nhật liên tục – trong trường hợp này là toàn bộ thông tin tuyển sinh của một trường đại học – để tạo ra các câu trả lời chính xác, phù hợp với ngữ cảnh và đáng tin cậy thay vì chỉ dựa vào các kiến thức trong quá trình huấn luyện của mô hình.

Xuất phát từ những nhu cầu thực tiễn của thí sinh và các trường đại học, cùng với tiềm năng ứng dụng của các mô hình ngôn ngữ lớn đang phát triển không ngừng hiện nay, đề tài "Xây dựng hệ thống tư vấn tuyển sinh thông minh dựa trên mô hình hội thoại tự động" được đề xuất. Luận văn này tập trung vào việc nghiên cứu và phát triển một hệ thống chatbot sử dụng các mô hình ngôn ngữ lớn mạnh mẽ kết hợp với các kỹ thuật RAG hiện đại nhằm cung cấp một hệ thống có thể trả lời các thông tin liên quan đến tuyển sinh đại học một cách hiệu quả, đáng tin cậy và chính xác.

1.2 Mục tiêu của đề tài

Mục tiêu của đề tài là xây dựng một hệ thống tư vấn tuyển sinh thông minh dựa trên mô hình hội thoại tự động (hay chatbot) nhằm hỗ trợ trong việc trả lời và giải đáp

các thách thức liên quan đến tuyển sinh đại học của Đại học Cần Thơ. Nghiên cứu tập trung vào việc ứng dụng các mô hình ngôn ngữ lớn hiện đại, kết hợp với kỹ thuật truy xuất thông tin nhằm cải thiện độ chính xác khi truy vấn trên các thông tin chuyên biệt.

Ngoài ra, việc thu thập và xử lý dữ liệu cũng là một phần quan trọng góp phần vào độ chính xác của hệ thống. Nghiên cứu cũng thảo luận về quá trình thu thập dữ liệu từ đề án tuyển sinh của Đại học Cần Thơ năm 2025, quá trình tiền xử lý dữ liệu cho hệ thống RAG, cùng với đó là những kỹ thuật cải thiện RAG phổ biến để cải thiện độ chính xác và tăng độ tin cậy của hệ thống.

1.3 Các nghiên cứu liên quan

Trong những năm gần đây, việc ứng dụng trí tuệ nhân tạo (AI) vào giáo dục, đặc biệt là trong các hệ thống hội thoại tự động (chatbot), đã trở thành một hướng nghiên cứu quan trọng nhằm hỗ trợ các hoạt động tư vấn và giải đáp thắc mắc. Các mô hình ngôn ngữ lớn (LLMs) như GPT [4], Gemini [5], và Grok [6; 7] đã được chứng minh là có khả năng cung cấp câu trả lời nhanh chóng và tự nhiên, giảm tải cho đội ngũ tư vấn truyền thống. Đặc biệt, kỹ thuật Retrieval-Augmented Generation (RAG) [14] đã nổi lên như một giải pháp hiệu quả để cải thiện độ chính xác và tính phù hợp của các câu trả lời trong các lĩnh vực chuyên biệt, chẳng hạn như tư vấn tuyển sinh đại học, lĩnh vực y tế, pháp luật, bằng cách kết hợp thông tin từ cơ sở tri thức bên ngoài với khả năng suy luận, truy xuất thông tin và ngữ cảnh và sinh ra phản hồi tự nhiên của LLMs.

Nghiên cứu của Lewis và cộng sự [14] là một trong những công trình tiên phong đề xuất mô hình RAG, kết hợp giữa truy xuất thông tin và sinh văn bản để nâng cao chất lượng câu trả lời trong các hệ thống hỏi đáp mở. Công trình này đã đặt nền móng cho các ứng dụng RAG trong nhiều lĩnh vực, bao gồm giáo dục, nơi mà việc cung cấp thông tin chính xác và cập nhật là yếu tố then chốt. Trong bối cảnh tuyển sinh đại học, RAG cho phép hệ thống truy xuất thông tin từ các nguồn dữ liệu chuyên biệt như đề án tuyển sinh, qua đó đảm bảo câu trả lời không chỉ dựa trên kiến thức tĩnh của mô hình mà còn phản ánh thông tin thực tế và mới nhất.

Để nâng cao hiệu quả truy xuất thông tin, nghiên cứu của Karpukhin và cộng sự [10] về Dense Passage Retrieval (DPR) đã đề xuất sử dụng các vector dày đặc (dense vectors) để biểu diễn văn bản, cải thiện đáng kể khả năng tìm kiếm thông tin so với các phương pháp truyền thống như TF-IDF hay BM25 [15]. Kỹ thuật này đặc biệt phù hợp với hệ thống tư vấn tuyển sinh, nơi cần xử lý nhanh chóng và chính xác một lượng lớn dữ liệu văn bản từ các tài liệu tuyển sinh. Tiếp nối hướng nghiên cứu này, Ren và cộng sự [12] đã phát triển RocketQAv2, một phương pháp huấn luyện chung cho cả thành phần truy xuất (retriever) và thành phần xếp hạng (reranker), giúp hệ thống thích ứng tốt hơn với các câu hỏi phức tạp.

Một thách thức quan trọng trong việc triển khai các hệ thống chatbot là đánh giá hiệu quả khi không có câu trả lời tham chiếu, một vấn đề phổ biến trong các ứng dụng thực tế như tư vấn tuyển sinh. Nghiên cứu của Saad-Falcon và cộng sự [16] đã đề xuất ARES, một framework đánh giá tự động cho các hệ thống RAG, dựa trên các tiêu chí như độ phù hợp của ngữ cảnh, độ trung thực và độ liên quan của câu trả lời. Phương pháp này cung cấp một cách tiếp cận có hệ thống để đánh giá hiệu suất của hệ thống, đặc biệt trong các tình huống mà dữ liệu tham chiếu bị hạn chế, từ đó hỗ trợ việc tối ưu hóa hệ thống tư vấn tuyển sinh thông minh. Phương pháp này có thể coi như một

cải tiến của RAGAS [17], một framework tương tự, tuy nhiên RAGAS phụ thuộc vào một danh sách các prompt được thiết kế thủ công, việc này có thể giảm khả năng thích ứng khi áp dụng vào dữ liệu ở các miền dữ liệu khác.

Ngoài ra, các kỹ thuật tối ưu hóa RAG như hybrid retrieval [11; 18], kết hợp giữa Sparse và Dense Retrieval, hay Query Rewriting [19] cũng đã được chứng minh là có khả năng nâng cao độ chính xác của hệ thống khi xử lý các câu hỏi không rõ ràng hoặc phức tạp. Những phương pháp này đặc biệt hữu ích trong bối cảnh tư vấn tuyển sinh, nơi thí sinh có thể đặt các câu hỏi đa dạng về tổ hợp xét tuyển, học phí, hay cơ hội việc làm sau khi tốt nghiệp. Nghiên cứu của Chuang và cộng sự [18] cho thấy việc kết hợp các phương pháp truy xuất khác nhau giúp tăng cường khả năng bao phủ thông tin, trong khi Ma và cộng sự [19] nhấn mạnh tầm quan trọng của việc tái diễn đạt câu hỏi để cải thiện kết quả truy xuất.

Tóm lại, các nghiên cứu liên quan đã cung cấp một nền tảng lý thuyết và thực tiễn vững chắc cho việc phát triển hệ thống tư vấn tuyển sinh thông minh. Bằng cách tận dụng các tiến bộ trong LLMs và RAG, cùng với các kỹ thuật tối ưu hóa truy xuất thông tin. Những công trình này không chỉ khẳng định tính khả thi của giải pháp mà còn mở ra hướng nghiên cứu sâu hơn để nâng cao hiệu quả và độ tin cậy của hệ thống trong thực tế.

1.4 Đối tượng và Phạm vi nghiên cứu

Đối tượng nghiên cứu chính của luận văn là các kỹ thuật và mô hình được sử dụng để xây dựng một hệ thống chatbot tư vấn tuyển sinh thông minh. Cụ thể, bao gồm các mô hình ngôn ngữ lớn mạnh mẽ và hiện đại nhất hiện nay; kỹ thuật Retrieval-Augmented Generation (RAG) để cải thiện độ chính xác và hiệu quả của chatbot trên dữ liệu chuyên biệt; quy trình trích xuất các thông tin từ đề án tuyển sinh của Đại học Cần Thơ; và cuối cùng là nghiên cứu các phương pháp để đánh giá độ hiệu quả của các kỹ thuật được áp dụng cũng như để đánh giá chính xác và hiệu quả của hệ thống cuối cùng.

Phạm vi nghiên cứu bao gồm nhiều khía cạnh khác nhau, từ việc ứng dụng các mô hình ngôn ngữ lớn hiện đại, các kỹ thuật tối ưu cho hệ thống RAG, quy trình thu thập và xử lý dữ liệu cho hệ thống RAG và quy trình đánh giá hệ thống.

Về mô hình được sử dụng, nghiên cứu tập trung vào việc ứng dụng một số mô hình ngôn ngữ lớn hiện đại và mạnh mẽ như GPT-4o, GPT-4.1, Gemini 2.5, Grok-3, Claude-4. Về các kỹ thuật tối ưu RAG, nghiên cứu đi từ các kỹ thuật cơ bản thường được áp dụng như Sparse Retrieval [20], Dense Retrieval [10], cho đến các kỹ thuật tối ưu như Query Rewriting [19], Reciprocal Rerank Fusion và Reranking.

Về việc thu thập và xử lý dữ liệu cho hệ thống RAG, luận văn nghiên cứu cách tổng hợp thông tin từ nhiều định dạng (HTML, PDF, ...), phương pháp xử lý các nội dung có cấu trúc như các bảng và việc chia nhỏ dữ liệu thành các chunks. Và cuối cùng là việc đánh giá hệ thống chatbot dựa trên RAG trong điều kiện không có các câu trả lời tham chiếu để đánh giá độ chính xác của câu trả lời của hệ thống.

1.5 Phương pháp nghiên cứu

Quá trình nghiên cứu tập trung vào việc khảo sát và tìm hiểu các nghiên cứu đưa ra các khái niệm cơ sở như kiến trúc Transformer, hệ thống truy xuất, hệ thống hỏi đáp, BM25, truy xuất dày đặc cho đến các công trình nghiên cứu gần đây về các kỹ thuật liên quan đến Retrieval-Augmented Generation (RAG) giúp cải thiện hiệu suất

của hệ thống RAG như hybrid retrieval, query rewriting hay reranking. Việc khảo sát này nhằm mục đích nghiên cứu để đề xuất ra giải pháp phù hợp cho luận văn này.

Quá trình nghiên cứu được bắt đầu bằng cách tìm hiểu các phương pháp hiện đại để trích xuất thông tin từ đa dạng các nguồn khác nhau (website, PDF, ...), thực hiện tiền xử lý dữ liệu cho hệ thống RAG như thực hiện embedding, xử lý các bảng, công thức và ảnh trong tài liệu. Cụ thể, nghiên cứu áp dụng các công cụ FireCrawl cho việc thu thập dữ liệu ở các website, Marker cho việc trích xuất thông tin từ PDF và áp dụng mô hình ngôn ngữ lớn cho các bước xử lý còn lại (như chuyển công thức từ ảnh sang $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ hay tóm tắt nội dung bảng). Sau khi đã hoàn thành bước thu thập và tiền xử lý dữ liệu, các dữ liệu này được thêm vào các database để phục vụ cho việc truy xuất thông tin, cụ thể là Postgres cho việc lưu dữ liệu và Qdrant cho việc lưu các embedding vectors.

Ở giai đoạn xử lý truy vấn của hệ thống, để tăng độ chính xác cho thành phần truy xuất của hệ thống, các kỹ thuật như Query rewriting (Query expansion) và Reranking được áp dụng để tăng độ chính xác của hệ thống, output đầu ra từ thành phần truy xuất kết hợp với câu truy vấn đầu vào được đưa vào một mô hình ngôn ngữ lớn để sinh ra câu trả lời cho người dùng.

Cuối cùng là phần đánh giá hệ thống, trong đó bao gồm hai phần chính là đánh giá độ hiệu quả của thành phần truy xuất với các chỉ số như Recall, MRR, MAP và NDCG và phần thứ hai là đánh giá câu phản hồi được sinh ra với các chỉ số như *Faithfulness*, *Answer relevance* và *Context Relevance*.

1.6 Cấu trúc luận văn

Cấu trúc của quyển luận văn được chia thành sáu chương chính. Chương 1 giới thiệu tổng quan về đề tài, đặt vấn đề, nêu mục tiêu của đề tài, đối tượng và phạm vi nghiên cứu của đề tài. Ngoài ra còn trình bày về các nghiên cứu có liên quan cùng với phương pháp thực hiện được sử dụng để hiện thực hoá đề tài.

Nội dung Chương 2 trình bày các cơ sở lý thuyết làm nền tảng cho nghiên cứu này. Phần này trình bày tổng quan về kiến trúc mô hình Transformer, từ kiến trúc Transformer đến các mô hình ngôn ngữ lớn hiện đại, Retrieval-Augmented Generation, truy xuất thưa và truy xuất dày đặc và cuối cùng là giới thiệu về các chỉ số đánh giá hệ thống RAG được dùng trong nghiên cứu.

Chương 3 trình bày về phương pháp thực hiện, bao gồm việc thu thập dữ liệu, tiền xử lý dữ liệu cho RAG, cách truy xuất thông tin của thành phần truy xuất, một số kỹ thuật tối ưu RAG và cuối cùng là phương pháp sinh câu trả lời sử dụng mô hình ngôn ngữ lớn.

Phần thực nghiệm được thảo luận ở Chương 4, bao gồm giới thiệu về môi trường thực nghiệm, dữ liệu được dùng cho phần đánh giá hệ thống, các kết quả đánh giá trên thành phần truy xuất, đánh giá trên phần phản hồi, đánh giá trên thời gian phản hồi của hệ thống và cuối cùng là phần thảo luận.


Cuối cùng, Chương 5 tổng hợp lại các kết quả đạt được, rút ra các nhận định và đề xuất các phương pháp có thể cải thiện hệ thống cho các nghiên cứu trong tương lai.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

2.1 Kiến trúc Transformer

Kiến trúc Transformer, được giới thiệu bởi Vaswani và cộng sự trong bài báo *Attention is All You Need* (2017) [21], là một mô hình học sâu mang tính cách mạng trong lĩnh vực xử lý ngôn ngữ tự nhiên. Không giống các mô hình trước đó dựa trên mạng nơ-ron hồi quy (RNN) hay mạng nơ-ron tích chập (CNN), Transformer sử dụng cơ chế tự chú ý để xử lý các chuỗi đầu vào một cách song song, giúp tăng hiệu quả tính toán và khả năng mở rộng. Sự đổi mới này đã đặt nền móng xuất hiện cho rất nhiều các mô hình ngôn ngữ dựa trên kiến trúc Transformer, từ giai đoạn rất sớm như BERT [22], BART [23], cho đến thời điểm hiện tại như GPT-4 [4], Gemini 2.5 [24], Grok-3 [6], Claude 4 [9], vốn là các thành phần quan trọng trong hệ thống tư vấn tuyển sinh thông minh được đề xuất trong luận văn này. Minh hoạ về kiến trúc của Mô hình Transformer được thể hiện ở Hình 2.1.



Hình 2.1: Minh hoạ kiến trúc của mô hình Transformer [21].

2.1.1 Cơ chế tự chú ý

Cơ chế tự chú ý là trung tâm của kiến trúc Transformer, cho phép mô hình đánh giá mức độ quan trọng của các từ trong một chuỗi so với nhau, từ đó nắm bắt được các phụ thuộc dài hạn hiệu quả hơn so với các mô hình RNN.

Cho một chuỗi đầu vào $X = [x_1, x_2, \dots, x_n]$, trong đó mỗi x_i là một vector có số chiều là d , đầu vào này được ánh xạ thành ba vector **Query** (Q), **Key** (K), và **Value** (V). Các vector này được tạo bằng cách nhân X với các ma trận trọng số học:

$$Q = XW^Q, \quad K = XW^K, \quad V = XW^V, \quad (2.1)$$

trong đó $W^Q, W^K \in \mathbb{R}^{d \times d_k}$ và $W^V \in \mathbb{R}^{d \times d_v}$. Thông thường, $d_k = d_v = \frac{d}{h}$, với h là số lượng đầu chú ý.

Lúc này, cơ chế Attention được tính như sau:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.2)$$

Trong công thức 2.2 ở trên, việc chia QK^T cho $\sqrt{d_k}$ có tác dụng chuẩn hoá giúp giữ giá trị phương sai xấp xỉ 1, với giả định rằng các tham số Q và K chứa các biến ngẫu nhiên với giá trị trung bình là 0 và phương sai là 1 [21].

Cơ chế này cho phép mô hình tập trung vào các phần liên quan của chuỗi đầu vào khi xử lý từng vị trí.

2.1.2 Chú ý đa đầu

Transformer sử dụng chú ý đa đầu để tăng cường khả năng học, cho phép mô hình chú ý đến thông tin từ nhiều không gian biểu diễn khác nhau. Cơ chế này thực hiện tự chú ý h lần với các phép chiếu tuyến tính riêng biệt, sau đó kết quả từ các đầu sẽ được tổng hợp bằng cách nối lại với nhau.

Cụ thể, cho mỗi đầu i :

$$\text{head}_i = \text{Attention}(Q_i, K_i, V_i), \quad (2.3)$$

với

$$Q_i = XW_i^Q, \quad K_i = XW_i^K, \quad V_i = XW_i^V \quad (2.4)$$

Đầu ra của các đầu chú ý được nối lại và chiếu tuyến tính như sau:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O \quad (2.5)$$

trong đó $W_i^Q \in \mathbb{R}^{d \times d_k}, W_i^K \in \mathbb{R}^{d \times d_k}, W_i^V \in \mathbb{R}^{d \times d_v}$ và $W^O \in \mathbb{R}^{hd_v \times d}$ là các ma trận học.

2.1.3 Mạng truyền thẳng

Mỗi lớp chứa một mạng nơ-ron truyền thẳng áp dụng riêng cho từng vị trí trong chuỗi:

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2, \quad (2.6)$$

trong đó W_1, W_2 là ma trận trọng số, b_1, b_2 là vector bias, và $\max(0, \cdot)$ là hàm kích hoạt ReLU.

2.1.4 Chuẩn hoá theo tầng

Chuẩn hoá là một quá trình chuyển đổi các thuộc tính về các tỉ lệ tương tự nhau. Ví dụ như một thuộc tính có khoảng giá trị rộng (các giá trị nằm trong khoảng $[1, 100]$), một thuộc tính khác lại có khoảng giá trị nhỏ (trong khoảng $[0, 1]$) việc này có thể làm mất cân bằng giữa các thuộc tính.

Trong mô hình Transformer, chuẩn hoá theo tầng (Layer Normalization) [25] (hay LayerNorm) đóng một vai trò quan trọng giúp quá trình huấn luyện của mô hình được ổn định và hội tụ nhanh hơn. Việc thiếu đi LayerNorm đôi khi dẫn đến quá trình huấn luyện không hội tụ [26].

Trong mô hình Transformer, quá trình chuẩn hoá LayerNorm được thực hiện như sau:

$$y = \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} \odot \gamma + \beta, \quad (2.7)$$

trong đó x là đầu vào; μ và σ là giá trị trung bình và độ lệch chuẩn của x ; ϵ là một giá trị nhỏ nhằm tránh việc chia cho không; $\odot$ là phép nhân theo từng phần tử (element-wise); γ và β là hai tham số học có kích thước giống với x , thông thường thì ban đầu γ được khởi tạo với các giá trị bằng 1 và β được khởi tạo với các giá trị bằng 0. Hai giá trị trung bình μ và độ lệch chuẩn σ được tính theo các công thức:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i, \quad \sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2} \quad (2.8)$$

2.1.5 Kiến trúc mô hình

Mô hình Transformer bao gồm hai khối chính là khối mã hoá (encoder) và khối giải mã (decoder). Trong đó mỗi khối đều bao gồm nhiều tầng giống nhau chất chồng lên nhau và mỗi tầng bao gồm hai tầng con có chứa Multi-head attention, được theo sau bởi một mạng truyền thẳng (feed-forward network) và sau đó là kết nối tàn dư (residual connect) cùng với layer normalization. Khối mã hoá có nhiệm vụ mã hoá chuỗi đầu vào thành các embedding vectors giàu ngữ nghĩa và khối giải mã sinh output đầu ra dựa trên input đầu vào kết hợp với các embedding vectors ngữ nghĩa từ khối mã hoá làm ngữ cảnh.

Ngoài các thành phần chính này, kiến trúc Transformer còn áp dụng các kỹ thuật khác bao gồm kết nối phần dư (residual connection) giúp mô hình giữ được các đặc trưng đầu vào cũng như giảm thiểu các vấn đề liên quan đến biến mất gradient và mã hoá vị trí (positional encoding) giúp giữ các thông tin về vị trí vì cơ chế attention xử lý các token một cách đồng thời do đó cần lưu lại các thông tin về vị trí.

2.2 Từ kiến trúc Transformer đến các mô hình ngôn ngữ lớn hiện đại

Trong giai đoạn đầu tiên của lĩnh vực xử lý ngôn ngữ tự nhiên, các mô hình chủ yếu là các mô hình dạng thống kê, sau đó phát triển lên các mô hình mạng nơ-ron và tiếp đến sau này kiến trúc Transformer đã đặt nền móng cho sự xuất hiện của vô số các mô hình ngôn ngữ hiện đại và giai đoạn đầu tiên là các mô hình được huấn luyện sẵn (pre-trained language models - PLMs). Các mô hình PLMs được huấn luyện theo phương pháp self-supervised trên một tập văn bản rất lớn với mong muốn mô hình sẽ

học được sự biểu diễn tổng quát đối với nhiều lĩnh vực khác nhau, sau đó các PLMs này được tinh chỉnh trên các tác vụ cụ thể.

PLMs và LLMs. Các nghiên cứu đã chỉ ra rằng các PLMs càng lớn sẽ đạt kết quả càng cao, từ đó dẫn đến sự chuyển biến từ PLMs thành LLMs bằng cách tăng số lượng tham số của mô hình lên một cách đáng kể (lên đến hàng tỉ tham số) và huấn luyện mô hình trên tập dữ liệu lớn hơn [27]. Các mô hình ngôn ngữ lớn (LLMs) trong giai đoạn gần đây đã chứng minh khả năng đáng kinh ngạc đối với các tác vụ xử lý ngôn ngữ tự nhiên, từ đó dẫn đến việc ra đời hàng loạt các nghiên cứu khác đóng góp cho hướng phát triển này. Các nghiên cứu này thường đóng góp vào các chủ đề như thay đổi kiến trúc mô hình, chiến lược huấn luyện tốt hơn, kỹ thuật lọc dữ liệu tốt hơn, huấn luyện một cách hiệu quả hơn.

Các mô hình ngôn ngữ lớn hiện đại. Sự phát triển của LLMs đã dẫn đến sự ra đời của nhiều mô hình mạnh mẽ, trong đó nổi bật là các mô hình như GPT-4 [4], Grok [7], Gemini [24] hay Claude [9] là một số đại diện tiêu biểu cho các mô hình **mã nguồn đóng** và các mô hình như DeepSeek [28], Qwen [29], Mixtral [30] là một số đại diện tiêu biểu cho các mô hình **mã nguồn mở**. Những mô hình này không chỉ có số lượng tham số khổng lồ mà còn được huấn luyện trên các tập dữ liệu đa dạng và phong phú, giúp chúng đạt được khả năng hiểu và sinh ngôn ngữ tự nhiên một cách ấn tượng.

Mô hình ngôn ngữ lớn tích hợp công cụ. Một xu hướng mới trong phát triển LLMs là tích hợp các công cụ (tools) để mở rộng khả năng của mô hình. Các công cụ này có thể là các API, cơ sở dữ liệu, hoặc các mô hình chuyên biệt, giúp LLMs truy xuất thông tin bên ngoài, thực hiện các tác vụ cụ thể, và cung cấp câu trả lời chính xác hơn thay vì chỉ dựa vào các kiến thức được lưu trong tham số của mô hình trong quá trình huấn luyện.

Trong số các giải pháp để tích hợp công cụ vào LLMs, **Model Context Protocol** (hay MCP) [31] nổi bật như một phần quan trọng giúp quản lý và cung cấp các công cụ thông qua một giao thức thống nhất.

Một MCP server có thể được hiểu đơn giản như RESTful API nhưng được thiết kế chuyên biệt dành cho LLMs, đây là nơi *đóng gói* chứa tất cả những tài nguyên và công cụ cần thiết để các mô hình LLMs có thể *truy xuất, tương tác* và *tác động* đến thế giới bên ngoài một cách hiệu quả và thống nhất. Thông qua việc tích hợp MCP server, các LLMs có thể truy xuất các nguồn tài nguyên hiện có mà server cung cấp (như các prompts, files, ảnh, ...) hay gọi đến các hàm được cung cấp và truyền các tham số tương ứng để thực hiện các tác vụ mong muốn.

2.3 Hệ thống hỏi đáp

Hệ thống hỏi đáp (Question Answering System) là một lĩnh vực cốt lõi trong xử lý ngôn ngữ tự nhiên, nhằm xây dựng các mô hình máy tính có khả năng hiểu và trả lời các câu hỏi của con người một cách tự động, dựa trên nguồn dữ liệu đầu vào. Theo [14], QA có thể được định nghĩa như quá trình trích xuất hoặc sinh ra câu trả lời chính xác từ một tập dữ liệu hoặc kho kiến thức, giúp giảm thiểu nhu cầu tìm kiếm thủ công và nâng cao hiệu quả tương tác giữa người dùng và hệ thống thông tin. Lĩnh vực này đã phát triển mạnh mẽ từ những năm 1960 với các hệ thống dựa trên quy tắc, đến các

mô hình học sâu hiện đại, đặc biệt là sau sự ra đời của các mô hình ngôn ngữ lớn như BERT [22] và GPT [32].

Các hệ thống QA thường được phân loại **dựa trên phạm vi kiến thức** và **phương pháp xử lý**. Về phạm vi, có hai loại chính: QA mở (Open-Domain QA - ODQA) và QA đóng (Closed-Domain QA). ODQA xử lý các câu hỏi từ bất kỳ chủ đề nào, thường dựa trên nguồn kiến thức mở như Wikipedia, với các nghiên cứu tiêu biểu có liên quan như DrQA [33] sử dụng kết hợp tìm kiếm dựa trên TF-IDF và mô hình RNN để trích xuất câu trả lời từ các đoạn văn. Ngược lại, QA đóng tập trung vào một lĩnh vực cụ thể, chẳng hạn như y tế hoặc giáo dục, nơi nguồn dữ liệu được giới hạn để đảm bảo độ chính xác cao hơn.

Về phương pháp, QA có thể được chia thành: **(1)** Dựa trên trích xuất (extractive QA), nơi câu trả lời được lấy trực tiếp từ văn bản nguồn, như trong SQuAD [34]; **(2)** Dựa trên tạo sinh (generative QA), sử dụng mô hình như T5 [27] để tạo ra câu trả lời mới; và **(3)** Kết hợp (hybrid QA), thường tích hợp kỹ thuật Retrieval-Augmented Generation (RAG) để cải thiện khả năng truy xuất kiến thức bên ngoài. RAG, được giới thiệu bởi [14], kết hợp bộ truy xuất để lấy thông tin liên quan từ kho dữ liệu kết hợp với một mô hình sinh để sinh ra câu trả lời, giúp giảm thiểu hiện tượng *ảo tưởng* - nơi mô hình sinh ra thông tin sai lệch. Các nghiên cứu gần đây như [10] về Dense Passage Retrieval (DPR) đã chứng minh rằng RAG có thể nâng cao độ chính xác trong ODQA lên đến 10-20% so với mô hình thuần túy dựa trên tham số.

Trong đề tài này, hệ thống tư vấn tuyển sinh được xây dựng như một **hệ thống QA đóng**, tập trung vào dữ liệu tuyển sinh của Đại học Cần Thơ năm 2025, sử dụng các mô hình ngôn ngữ lớn như *GPT-4o*, *GPT-4.1* và *Gemini 2.5 Flash* kết hợp RAG để xử lý các câu hỏi đa dạng từ người dùng. Phương pháp này không chỉ đảm bảo tính chính xác khi truy xuất các thông tin từ đề án tuyển sinh mà còn hỗ trợ các cuộc hội thoại một cách tự nhiên và thân thiện với người dùng.

2.4 Retrieval-Augmented Generation

Retrieval-Augmented Generation (RAG) là một kỹ thuật đang nhận được rất nhiều sự quan tâm của giới nghiên cứu trong giai đoạn gần đây, kết hợp giữa truy xuất thông tin (retrieval) và sinh ngôn ngữ (generation) để nâng cao khả năng của các mô hình ngôn ngữ lớn trong việc xử lý các tác vụ yêu cầu kiến thức chuyên sâu hoặc về lĩnh vực chuyên biệt nào đó. Được giới thiệu bởi Lewis cùng cộng sự trong bài báo *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks* (2020) [14], RAG tích hợp một thành phần truy xuất để tìm kiếm thông tin từ cơ sở tri thức bên ngoài, sau đó sử dụng thông tin này làm ngữ cảnh cho quá trình sinh ngôn ngữ. Việc sinh ngôn ngữ dựa trên những ngữ cảnh truy xuất được thường được thực hiện thông qua việc tích hợp một mô hình ngôn ngữ.

Trong bối cảnh hệ thống tư vấn tuyển sinh, RAG cho phép truy xuất thông tin từ các nguồn dữ liệu như trang web của trường đại học, tài liệu tuyển sinh, hoặc cơ sở dữ liệu câu hỏi thường gặp, kết hợp với khả năng sinh ngôn ngữ của các mô hình như ChatGPT, Gemini, hoặc Grok để tạo ra các câu trả lời tự nhiên và phù hợp. Điều này giúp khắc phục hạn chế của các LLMs thông thường, vốn chỉ dựa vào kiến thức tĩnh được huấn luyện trước và có thể không phản ánh thông tin mới nhất.

2.4.1 Nguồn gốc và sự phát triển

Trước RAG, các hệ thống hỏi đáp thường tách biệt giữa truy xuất thông tin và sinh ngôn ngữ. Các phương pháp truy xuất truyền thống như TF-IDF hoặc BM25 [15] hiệu quả trong việc tìm kiếm tài liệu liên quan, nhưng không thể sinh ra câu trả lời tự nhiên. Ngược lại, các mô hình sinh ngôn ngữ có khả năng tạo văn bản mạch lạc, nhưng dễ gặp hiện tượng *hallucination* (hiện tượng ảo giác khiến mô hình sinh ra các thông tin không chính xác). RAG ra đời như một giải pháp kết hợp ưu điểm của cả hai, đánh dấu bước tiến từ các hệ thống truy xuất đơn thuần sang các mô hình tích hợp hiện đại. Một ví dụ điển hình cho trường hợp này là DrQA [33], trong đó họ đề xuất phương pháp áp dụng Bigram hashing kết hợp với TF-IDF để truy xuất thông tin với nguồn dữ liệu là Wikipedia, sau đó kết hợp với RNN cho việc sinh đáp án.

Sự phát triển của RAG được củng cố bởi các nghiên cứu như *Dense Passage Retrieval for Open-Domain Question Answering* (2020) [10], giới thiệu **DPR** để cải thiện độ chính xác của truy xuất, *Improving the Domain Adaptation of Retrieval Augmented Generation (RAG) Models for Open Domain Question Answering* (2023) [32], tập trung vào việc tinh chỉnh RAG cho các lĩnh vực chuyên biệt.

2.4.2 Các thành phần chính của hệ thống RAG

Một hệ thống RAG thông thường sẽ bao gồm hai thành phần chính là thành phần truy xuất (retriever) và mô hình sinh (generator).

Thành phần truy xuất (Retriever). Thành phần truy xuất có nhiệm vụ tìm kiếm các tài liệu hoặc đoạn văn bản liên quan từ cơ sở tri thức. Các loại truy xuất phổ biến bao gồm:

- *Truy xuất thưa (Sparse Retrieval)*: Dựa trên BM25 hoặc TF-IDF, biểu diễn văn bản dưới dạng vector thưa (sparse vector), ưu tiên tính toán nhanh nhưng hạn chế trong việc nắm bắt ngữ nghĩa sâu.
- *Truy xuất dày đặc (Dense Retrieval)*: Sử dụng các mô hình như DPR [10], mã hóa câu hỏi và tài liệu thành vector dày đặc (dense vector) bằng các mô hình mã hoá như BERT [22] hay Sentence-BERT [35], các dense vector này sau đó được tính độ tương đồng thông qua độ tương tự cosine (cosine similarity) hoặc tích vô hướng (dot product). Phương pháp này có phần cải thiện so với việc sử dụng sparse vector, trong đó các câu được biểu diễn bằng những từ những khác nhau nhưng mang ngữ nghĩa tương tự nhau vẫn được truy xuất một cách hiệu quả.

Mô hình sinh (Generator). Mô hình sinh thường là một mô hình ngôn ngữ, mô hình này được cung cấp các tài liệu truy xuất được làm thông tin ngữ cảnh từ đó sinh ra câu trả lời chính xác và đáng tin cậy.

Một trong những phương pháp đơn giản nhất nhưng hiệu quả cho việc kết hợp retriever và generator là nối các tài liệu liên quan truy xuất được vào phần prompt cùng với câu hỏi. Lúc này mô hình sinh có nhiệm vụ chính là trích xuất các thông tin liên quan hữu ích trong phần ngữ cảnh mà có thể được dùng để trả lời câu hỏi tương ứng.

2.4.3 Một số kỹ thuật tối ưu RAG

Tái xếp hạng. Nogueira và cộng sự (2019) [36] sử dụng BERT làm cross-encoder¹ để tái xếp hạng tài liệu, nâng cao độ liên quan của kết quả truy xuất. Việc sắp xếp lại thứ tự của các tài liệu hay đoạn văn truy xuất đặc biệt hữu ích trong việc thiết kế prompt hiệu quả để nâng cao độ chính xác của các mô hình ngôn ngữ lớn. Các mô hình ngôn ngữ lớn thường **có hiện tượng giảm độ chính xác** khi các ngữ cảnh liên quan được đặt ở phần giữa và đạt độ chính xác cao nhất khi các ngữ cảnh liên quan được đặt ở đầu hoặc cuối, hiện tượng này còn được biết đến với tên gọi *Lost in the middle* [37].

Nguyên nhân của hiện tượng *Lost in the middle* này liên quan đến cơ chế chú ý trong các mô hình Transformer, vốn là nền tảng của nhiều mô hình ngôn ngữ lớn ngày nay. Cơ chế chú ý thường phân bổ trọng số cao hơn cho các token ở vị trí đầu và cuối của chuỗi, do hiệu ứng từ positional encoding hoặc do cách mô hình được huấn luyện để ưu tiên các phần thông tin dễ tiếp cận hơn. Ngoài ra, khi xử lý chuỗi dài, giới hạn về bộ nhớ và khả năng tính toán có thể làm giảm khả năng mô hình duy trì sự chú ý đồng đều trên toàn bộ chuỗi, khiến thông tin ở giữa bị mờ nhạt. Hơn nữa, dữ liệu huấn luyện thường chứa các mẫu văn bản có xu hướng nhấn mạnh thông tin quan trọng ở đầu hoặc cuối, dẫn đến mô hình học được cách ưu tiên các vị trí này. Hiện tượng *Lost in the middle* vì thế trở thành một thách thức trong việc cải thiện khả năng xử lý ngữ cảnh dài của các mô hình ngôn ngữ lớn, đặc biệt trong các hệ thống RAG mà ở đó các thông tin liên quan truy xuất được thường khá nhiều và việc ưu tiên các tài liệu liên quan nhất lên đầu hoặc cuối danh sách đóng một vai trò quan trọng trong hiệu suất của hệ thống RAG.

Truy xuất hỗn hợp. Kết hợp các ưu điểm giữa truy xuất thưa và truy xuất dày đặc bằng cách thực hiện truy xuất sử dụng cả hai phương pháp, theo sau là bước tổng hợp kết quả truy xuất từ hai phương pháp. Nội dung này được thảo luận cụ thể hơn ở mục 2.5.3.

Tái diễn đạt câu hỏi. Tái diễn đạt câu hỏi (Query Writing, đôi khi còn được biết đến với tên gọi Query expansion) cho thành phần truy xuất, tập trung vào việc tối ưu hoá ngôn ngữ đầu vào để thành phần truy xuất hiểu đúng ý định người dùng và thực hiện truy xuất một cách hiệu quả. Ma và cộng sự (2023) [19] cho thấy việc tái viết truy vấn (query rewriting) có thể cải thiện đáng kể chất lượng các kết quả truy xuất so với truy xuất bằng truy vấn gốc, trong nghiên cứu này, họ sử dụng một mô hình ngôn ngữ nhỏ (small language model) để thực hiện việc tái diễn đạt câu hỏi. Việc tái diễn đạt câu hỏi đặc biệt hữu ích trong các trường hợp mà câu hỏi từ người dùng khá mơ hồ, sử dụng các câu từ không phổ biến, hoặc một câu hỏi chứa rất nhiều câu hỏi con gây khó khăn cho việc truy xuất.

2.5 Truy xuất thưa, truy xuất dày đặc và truy xuất hỗn hợp

Trong các hệ thống hỏi đáp hiện đại, đặc biệt là những hệ thống dựa trên **Retrieval-Augmented Generation (RAG)**, việc truy xuất thông tin đóng vai trò cốt lõi để

¹Cross-encoder trong ngữ cảnh của RAG và reranking là việc áp dụng một encoder như BERT để tính toán điểm/độ liên quan của một đoạn văn truy xuất được so với câu hỏi, input đầu vào là câu hỏi và đoạn văn được nối lại với nhau và ngăn cách bởi [SEP] token.

cung cấp ngữ cảnh chính xác cho mô hình ngôn ngữ lớn. Hai phương pháp truy xuất chính được sử dụng là **truy xuất thưa (sparse retrieval)** và **truy xuất dày đặc (dense retrieval)**, mỗi phương pháp có ưu điểm và hạn chế riêng, tùy thuộc vào yêu cầu cụ thể của bài toán.

2.5.1 Truy xuất thưa

Truy xuất thưa là một phương pháp truyền thống trong tìm kiếm thông tin, đặc biệt hiệu quả khi xử lý các truy vấn dựa trên từ khóa. Phương pháp này biểu diễn văn bản dưới dạng **vector thưa (sparse vector)**², trong đó mỗi chiều của vector tương ứng với một từ trong từ điển, và giá trị thường được tính dựa trên tần suất xuất hiện của từ (Term Frequency - TF) hoặc các biến thể như **TF-IDF (Term Frequency-Inverse Document Frequency)**. Một trong những thuật toán tiêu biểu nhất của truy xuất thưa là **BM25** (Best Matching 25), được phát triển từ mô hình TF-IDF bởi Robertson và cộng sự (2009) [15].

BM25 — Thuật toán truy xuất thưa tiêu biểu. BM25 cải thiện khả năng xếp hạng tài liệu bằng cách điều chỉnh các tham số để phản ánh mức độ liên quan của tài liệu đối với truy vấn. Công thức tính điểm của BM25 cho một tài liệu d đối với truy vấn q được định nghĩa như sau:

$$\text{score}(d, q) = \sum_{t \in q} \text{IDF}(t) \cdot \frac{\text{TF}(t, d) \cdot (k_1 + 1)}{\text{TF}(t, d) + k_1 \cdot (1 - b + b \cdot \frac{|d|}{\text{avgdl}})}, \quad (2.9)$$

trong đó:

- **IDF(t)**: Nghịch đảo tần suất tài liệu của từ t , đo lường mức độ hiếm của từ trong tập tài liệu.
- **TF(t, d)**: Tần suất xuất hiện của từ t trong tài liệu d .
- **| d |**: Độ dài của tài liệu d .
- **avgdl**: Độ dài trung bình của các tài liệu trong bộ sưu tập.
- **k_1 và b** : Các tham số có thể điều chỉnh được (k_1 kiểm soát mức độ bão hòa của TF, b điều chỉnh tầm quan trọng của độ dài tài liệu).

BM25 đã được chứng minh là hiệu quả trong nhiều ứng dụng thực tế, chẳng hạn như hệ thống tìm kiếm web hoặc truy vấn tài liệu mà trong đó **các từ khoá đóng vai trò quan trọng** hoặc được tích hợp vào một giai đoạn nào đó trong các pipeline nhiều giai đoạn, được thể hiện trong các nghiên cứu liên quan như [20; 18; 38].

Ưu điểm và hạn chế của BM25. Một trong các ưu điểm nổi bật của BM25 là thuật toán này hoạt động nhanh, ít đòi hỏi tài nguyên tính toán, và phù hợp với các truy vấn yêu cầu khớp từ khóa chính xác. Tuy nhiên, BM25 vẫn còn khá nhiều hạn chế, vì thuật toán dựa vào sự trùng khớp từ khóa, do đó khó nắm bắt ngữ nghĩa sâu, đặc biệt với các truy vấn phức tạp hoặc khi người dùng sử dụng các từ đồng nghĩa hoặc các từ hiếm gặp.

²Vector thưa là các vector trong đó phần lớn các phần tử có giá trị là 0

2.5.2 Truy xuất dày đặc

Truy xuất dày đặc là một phương pháp hiện đại, tận dụng các mô hình học sâu như **BERT** [22] hoặc **Sentence-BERT** [35] để biểu diễn văn bản dưới dạng **vector dày đặc (dense vector)** trong không gian đa chiều. Các vector này không chỉ nắm bắt trên từ khóa mà còn nắm bắt được ngữ nghĩa và mối quan hệ phức tạp giữa các từ, cải thiện đáng kể khả năng truy xuất thông tin so với phương pháp thưa.

Dense Passage Retrieval (DPR) — Một ví dụ điển hình. Một trong những phương pháp tiêu biểu của truy xuất dày đặc là **Dense Passage Retrieval (DPR)**, được giới thiệu bởi Karpukhin và cộng sự (2020) [10]. DPR sử dụng hai bộ mã hóa BERT riêng biệt: một cho câu hỏi và một cho đoạn văn. Các vector dày đặc được tạo ra từ đầu ra của token [CLS] trong BERT, sau đó độ tương đồng giữa câu hỏi và đoạn văn được tính bằng **cosine similarity** hoặc **dot product**. DPR được huấn luyện để tối ưu hóa sự tương đồng giữa vector của câu hỏi và vector của đoạn văn liên quan, sử dụng kỹ thuật **in-batch negatives** [10] để phân biệt các đoạn văn không liên quan.

Ưu điểm và hạn chế của DPR. DPR vượt trội trong việc xử lý các truy vấn phức tạp yêu cầu hiểu ngữ nghĩa nhờ khả năng biểu diễn ngữ nghĩa sâu bằng các mô hình mã hoá như BERT hay Sentence-BERT. Tuy nhiên, một hạn chế của phương pháp này là đòi hỏi tài nguyên tính toán lớn, thường chậm hơn nhiều so với BM25, ngoài ra có thể kém hiệu quả khi xử lý tài liệu rất dài hoặc khi truy vấn trên các tài liệu mà khớp theo từ khoá đóng vai trò quan trọng.

2.5.3 Truy xuất hỗn hợp

Một số nghiên cứu liên quan như [11; 18] đề xuất kết hợp truy xuất thưa và dày đặc để tận dụng ưu điểm của cả hai phương pháp. Truy xuất thưa như BM25 hiệu quả trong việc phát hiện sự trùng khớp dựa trên các từ khoá, phương pháp này đặc biệt hiệu quả với các tài liệu dài hoặc các truy vấn yêu cầu độ chính xác cao về từ khoá. Ngược lại, truy xuất dày đặc sử dụng các biểu diễn ngữ nghĩa từ mô hình như BERT để nắm bắt ý nghĩa sâu và phức tạp, phù hợp với các truy vấn phức tạp. Việc kết hợp ưu điểm của cả hai phương pháp truy xuất thưa và truy xuất dày đặc giúp cải thiện độ chính xác trên cả tìm kiếm trên từ khoá lẫn tìm kiếm theo ngữ nghĩa. Ngoài ra, các nghiên cứu liên quan như [11; 39] đề xuất **Multi-Vector Encodings**, trong đó thay vì chỉ biểu diễn tài liệu bằng một vector duy nhất, phương pháp này biểu diễn tài liệu dưới dạng tập hợp các vector, cải thiện hiệu quả truy xuất so với các mô hình bao gồm hai bộ giải mã (dual-encoder) truyền thống.

2.6 Các phương pháp đánh giá hệ thống RAG

Trong hệ thống tư vấn tuyển sinh thông minh dựa trên mô hình hội thoại tự động, việc đánh giá hiệu quả của hệ thống RAG là rất quan trọng để đảm bảo rằng các câu trả lời được cung cấp vừa chính xác vừa liên quan đến câu hỏi của người dùng. Phần này trình bày các chỉ số đánh giá cho thành phần truy xuất bao gồm Recall, Mean Reciprocal Rank (MRR), Mean Average Precision (MAP) và Normalized Discounted Cumulative Gain (NDCG) và các chỉ số đánh giá cho phản hồi của hệ thống bao gồm Faithfulness, Answer relevance và Context relevance.

2.6.1 Recall@k

Recall@k là một biến thể của chỉ số Recall, đo lường tỷ lệ tài liệu liên quan được hệ thống truy xuất thành công trong k tài liệu đầu tiên của danh sách kết quả so với tổng số tài liệu liên quan có sẵn. Công thức của Recall@k được định nghĩa như sau:

$$\text{Recall@k} = \frac{\text{Số lượng tài liệu liên quan trong top } k}{\text{Tổng số tài liệu liên quan}}, \quad (2.10)$$

trong đó k là số lượng tài liệu tối đa được xem xét trong danh sách kết quả.

Ý nghĩa của Recall@k nằm ở việc nó phản ánh mức độ toàn diện của giai đoạn truy xuất thông tin trong giới hạn k tài liệu đầu tiên.

2.6.2 Mean Reciprocal Rank - MRR@k

Mean Reciprocal Rank (MRR@k) đánh giá vị trí của tài liệu liên quan đầu tiên trong danh sách k kết quả được xếp hạng. Công thức của MRR@k được tính như sau:

$$\text{MRR@k} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}, \quad (2.11)$$

trong đó $|Q|$ là số lượng câu hỏi, rank_i là vị trí của tài liệu liên quan đầu tiên trong top k cho câu hỏi thứ i , và nếu không có tài liệu liên quan trong top k , giá trị đóng góp là 0.

MRR@k nhấn mạnh tầm quan trọng của việc đưa thông tin liên quan lên đầu danh sách kết quả trong phạm vi k tài liệu.

2.6.3 Mean Average Precision - MAP@k

Mean Average Precision (MAP@k) là một chỉ số toàn diện, kết hợp cả precision và recall để đánh giá chất lượng của danh sách k kết quả được xếp hạng. MAP@k tính trung bình precision tại mỗi vị trí của tài liệu liên quan trong top k . Công thức của Average Precision (AP@k) cho một câu hỏi được định nghĩa như sau:

$$\text{AP@k} = \frac{1}{\min(R, k)} \sum_{i=1}^k P(i) \times \text{rel}(i), \quad (2.12)$$

trong đó R là số lượng tài liệu liên quan, k là số lượng tài liệu được xem xét, $P(i)$ là precision tại vị trí i , và $\text{rel}(i)$ là 1 nếu tài liệu tại vị trí i liên quan, ngược lại là 0. MAP@k sau đó được tính bằng trung bình AP@k trên tất cả các câu hỏi:

$$\text{MAP@k} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \text{AP@k}_i \quad (2.13)$$

MAP@k cung cấp một điểm số duy nhất cân bằng giữa precision và recall trong top k tài liệu, phù hợp để đánh giá khả năng của hệ thống RAG trong việc cung cấp các câu trả lời vừa chính xác vừa đầy đủ.

2.6.4 Discounted Cumulative Gain - DCG@k và Normalized Discounted Cumulative Gain - NDCG@k

Discounted Cumulative Gain (DCG@k) đánh giá chất lượng của danh sách kết quả bằng cách gán trọng số cao hơn cho các tài liệu liên quan xuất hiện ở vị trí đầu trong top k . Công thức của DCG@k được tính như sau:

$$\text{DCG@k} = \sum_{i=1}^k \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)}, \quad (2.14)$$

trong đó rel_i là điểm liên quan của tài liệu tại vị trí i , và k là số lượng tài liệu được xem xét.

Normalized Discounted Cumulative Gain (NDCG@k) chuẩn hóa DCG@k bằng cách chia cho DCG lý tưởng (IDCG@k), là giá trị DCG tối đa có thể đạt được với xếp hạng hoàn hảo cho top k :

$$\text{NDCG@k} = \frac{\text{DCG@k}}{\text{IDCG@k}}$$

DCG@k và NDCG@k rất hữu ích trong việc đánh giá hệ thống RAG vì chúng xem xét cả *mức độ liên quan* và *thứ tự* của các tài liệu trong top k .

2.6.5 Faithfulness, Answer relevance và Context relevance

Khác với các chỉ số ở trên được dùng để đánh giá thành phần truy xuất của hệ thống RAG, các chỉ số trong mục này tập trung vào việc đánh giá phần phản hồi của hệ thống, cụ thể là *độ tin cậy*, *độ liên quan của câu trả lời* và *độ liên quan của các thông tin ngữ cảnh*.

Việc đánh giá hệ thống RAG với các chỉ số này được giới thiệu trong nghiên cứu của Shahul và cộng sự [17], bài nghiên cứu này giới thiệu RAGAS — **R**etrieval **A**ugmented **G**eneration **A**ssessment, một framework cho việc đánh giá các hệ thống RAG tập trung vào việc không cần câu trả lời tham chiếu cho việc đánh giá, một hiện tượng khá phổ biến trong các hệ thống chatbot dựa trên RAG, trong đó việc có các câu trả lời đúng để tham chiếu thường khá khó khăn, việc tạo các câu trả lời chính xác để tham chiếu thường thường phải được thực hiện một cách thủ công bởi con người và việc này thường tốn nhiều sức lực và tài nguyên.

Faithfulness. Chỉ số này đo lường độ tin cậy của câu trả lời được sinh ra. Với một câu trả lời $a_s(q)$ cho câu hỏi q , câu trả lời này được xem là đáng tin với ngữ cảnh $c(q)$ nếu những thông tin trong câu trả lời này có thể được suy ra từ ngữ cảnh $c(q)$. Một mô hình ngôn ngữ lớn được dùng để chia câu trả lời thành các *statements*, sau đó các *statements* được kiểm chứng xem có thể suy ra từ ngữ cảnh $c(q)$ hay không. Công thức của Faithfulness được thể hiện như sau:

$$\text{Faithfulness} = \frac{|V|}{|S|}, \quad (2.15)$$

trong đó $|V|$ là số *statements* hợp lệ và S là tổng số lượng *statements*.

Answer relevance. Chỉ số này đo lường độ liên quan của câu trả lời so với câu hỏi. Câu trả lời $a_s(q)$ được gọi là liên quan đến câu hỏi nếu câu trả lời này giải đáp được

các thách thức của câu hỏi một cách phù hợp. Chỉ số này không đánh giá về độ chính xác của câu trả lời mà nhấn mạnh vào việc đánh giá các trường hợp mà câu trả lời không hoàn chỉnh hoặc chứa các thông tin không liên quan. Phương pháp tính được thực hiện như sau: dựa trên câu trả lời $a_s(q)$, một mô hình ngôn ngữ lớn được dùng để sinh ra các câu hỏi q_i , các câu hỏi q_i này sau đó được dùng để tính độ tương tự so với câu hỏi gốc q với một mô hình *embedding*. Cuối cùng, Answer relevance được tính như sau:

$$\text{Answer relevance} = \frac{1}{n} \sum_{i=1}^n \text{sim}(q, q_i), \quad (2.16)$$

trong đó $\text{sim}(q, q_i)$ là độ tương tự cosine trong không gian embedding giữa q và q_i .

Context relevance. Chỉ số này tập trung vào việc đánh giá độ liên quan của các thông tin truy xuất được. Chỉ số này nhấn mạnh vào các trường hợp ngữ cảnh chứa các thông tin dư thừa và không liên quan. Với câu hỏi q và ngữ cảnh $c(q)$, một mô hình ngôn ngữ lớn được dùng để trích xuất tập các câu S_{ext} từ $c(q)$ mà là quan trọng để trả lời câu hỏi q . Khi đó Context relevance được tính theo công thức:

$$\text{Context relevance} = \frac{\text{số lượng câu trích xuất được}}{\text{tổng số lượng câu trong } c(q)} \quad (2.17)$$

Tóm tắt về ứng dụng của các chỉ số đánh giá. Trong hệ thống RAG, giai đoạn truy xuất (retrieval) tập trung vào việc truy xuất các tài liệu liên quan, do đó Recall@k là chỉ số được dùng để đánh giá độ chính xác của giai đoạn này, với k giới hạn số lượng tài liệu được xem xét. Ngược lại, giai đoạn xếp hạng lại (reranking) nhằm tối ưu hóa thứ tự của các tài liệu, do đó các chỉ số MRR@k, MAP@k, và NDCG@k được sử dụng để đánh giá chất lượng xếp hạng, đảm bảo thông tin quan trọng nhất được trình bày trước tiên trong top k tài liệu truy xuất được. Trong khi các chỉ số Faithfulness, Answer relevance và Context relevance thì được dùng vào việc đánh giá phần phản hồi của mô hình sinh.

CHƯƠNG 3

PHƯƠNG PHÁP THỰC HIỆN

3.1 Nguồn dữ liệu

Nguồn dữ liệu chính cho hệ thống đến từ đề án tuyển sinh năm 2025 của Đại học Cần Thơ¹, các thông tin này được chia vào các danh mục chính như đối tượng và chỉ tiêu tuyển sinh cho từng ngành, danh mục các ngành và tổ hợp xét tuyển, các phương thức xét tuyển, điểm ưu tiên trong xét tuyển, thông tin về các ngành của chương trình tiên tiến và chương trình chất lượng cao, Ngoài ra, các thông tin, thông báo, quy định chứa những thông tin liên quan cũng được thu thập trong nghiên cứu này như: Quyết định ban hành quy chế tuyển sinh đào tạo trình độ đại học hình thức chính quy², Đề án tổ chức Kỳ thi đánh giá đầu vào đại học trên máy tính phục vụ cho tuyển sinh đại học (V-SAT)³, Quy chế học vụ⁴,

Các nguồn dữ liệu này chia thành hai định dạng chính là HTML (các websites) và file PDF. Cả hai định dạng dữ liệu đều được xử lý và đưa về cùng một định dạng duy nhất là định dạng markdown. File markdown có cấu trúc trực quan và dễ hiểu, phù hợp cho các hệ thống RAG. Ngoài ra, định dạng markdown cũng phù hợp trong nghiên cứu này do có thể dễ dàng biểu diễn nội dung các website hay các file PDF sang định dạng markdown.

3.2 Tiền xử lý dữ liệu cho RAG

Tiền xử lý dữ liệu đóng vai trò then chốt trong việc nâng cao độ chính xác và hiệu quả của một hệ thống RAG, bằng cách đảm bảo rằng dữ liệu đầu vào được tối ưu hóa cho quá trình truy xuất cũng như cho quá trình sinh câu trả lời với các mô hình ngôn ngữ lớn. Sơ đồ tổng quan về quy trình thu thập và xử lý tài liệu của nghiên cứu này được minh họa ở Hình 3.1. Thông tin về số lượng dữ liệu cho từng định dạng HTML và PDF được thu thập trong nghiên cứu được trình bày chi tiết tại Bảng 3.1.

Tiền xử lý dữ liệu dạng website. Để thu thập và xử lý dữ liệu từ các website, công cụ Firecrawl⁵ được sử dụng nhằm phân tích và trích xuất nội dung từ các trang web một cách hiệu quả. Firecrawl là một công cụ mã nguồn mở, được thiết kế với sự tích hợp trí tuệ nhân tạo để tối ưu hoá việc trích xuất dữ liệu từ các website, đặc biệt là những trang có nội dung động và phức tạp, chẳng hạn như các trang sử dụng JavaScript nặng hoặc có cơ chế chống thu thập dữ liệu. Công cụ này cho phép chuyển


¹<https://tuyensinh.ctu.edu.vn/dai-hoc-chinh-quy/thong-tin-tuyen-sinh.html>

²https://www.ctu.edu.vn/images/upload/vbdh/vbct/QD6599_Quy_che_tuyen_sinh_dao_tao_dai_hoc_chinh_quy.pdf

³https://tuyensinh.ctu.edu.vn/images/upload/TT_TS/2025/De-an-to-chuc-Ky-thi-dan-h-gia-dau-vao-dai-hoc-tren-may-tinh-phuc-vu-tuyen-sinh-dai-hoc-V-SAT-cua-Truong-DHCT-nam-2025.pdf

⁴https://tansinhvien.ctu.edu.vn/images/upload/Tansinhvien_K50/Quychehocvu/QD3266_Quy_dinh_cong_tac_hoc_vu_danh_cho_sinh_vien_trinh_do_dai_hoc_hinh_thuc_chinh_quy_V3.pdf

⁵<https://github.com/mendableai/firecrawl>



Hình 3.1: Sơ đồ tổng quan về quy trình thu thập và xử lý dữ liệu

đổi nội dung website thành các định dạng có cấu trúc như Markdown, JSON, HTML hoặc dữ liệu thô, giúp các mô hình ngôn ngữ lớn dễ dàng xử lý và phân tích.

Lý do chính cho việc chọn Firecrawl chính là khả năng tự động hóa và đơn giản hoá quy trình thu thập dữ liệu. Không giống như các phương pháp truyền thống như sử dụng thư viện BeautifulSoup hoặc Scrapy, vốn đòi hỏi người dùng phải viết các kịch bản phức tạp để xử lý cấu trúc DOM hay vượt qua CAPTCHA, Firecrawl cung cấp một giao diện API đơn giản và mạnh mẽ. Chỉ với một lệnh gọi API, Firecrawl có thể trích xuất toàn bộ nội dung của một website, bao gồm cả văn bản, hình ảnh, liên kết, và siêu dữ liệu, mà không cần can thiệp thủ công.

Tiền xử lý dữ liệu dạng PDF. Đối với các tài liệu ở định dạng PDF, công cụ Marker⁶ được sử dụng để trích xuất nội dung của file PDF và lưu dưới dạng file markdown. Đối với công cụ Marker, ngoài trích xuất bằng các công cụ thủ công thì còn có thể cấu hình để sử dụng mô hình ngôn ngữ lớn để giải quyết các phần như gộp các bảng bị chia ở nhiều trang, xử lý các công thức toán, định dạng lại bảng, trích xuất text từ các biểu mẫu. Các mô hình được sử dụng bao gồm *GPT-4o* và *Gemini 2.5 Flash*.

Tiền xử lý nội dung markdown. Sau khi đã thu thập và xử lý các tài liệu thành các file markdown, các file markdown này sau đó được thực hiện chia nhỏ dựa trên việc chia theo các headers thành các sections, việc này được thực hiện thông qua *MarkdownHeaderTextSplitter* của LangChain. Sau đó với mỗi section, đầu tiên sẽ được trích xuất các bảng ra khỏi nội dung ban đầu, để có thể biểu diễn nội dung các từ các bảng này thành nội dung mà các mô hình ngôn ngữ lớn có thể hiểu được cũng như dễ dàng truy xuất với RAG thì mỗi dòng trong bảng được mô tả bằng việc kết hợp tiêu đề của cột và nội dung cột tương ứng của dòng đó. Quá trình mô tả bảng này sử dụng mô hình *GPT-4o*⁷, minh hoạ quy trình mô tả nội dung của bảng được trình bày tại

⁶<https://github.com/datalab-to/marker>

⁷<https://platform.openai.com/docs/models/gpt-4o>

Bảng 3.1: Thông tin về số lượng dữ liệu cho từng định dạng HTML và PDF được thu thập trong nghiên cứu cùng với số lượng section và chunk sau khi tiền xử lý dữ liệu

Định dạng dữ liệu	Số lượng tài liệu
HTML	36
PDF	9
Tổng số lượng tài liệu sau khi tiền xử lý (Markdown)	45
Số lượng section	267
Số lượng chunk	371

Hình 3.3 và prompt template được trình bày tại Phụ lục A.3.

Tuy nhiên, ở một số website nằm trong đề án tuyển sinh của trường, có một số website có chứa các công thức nhưng ở định dạng là file ảnh do đó khi chuyển sang định dạng markdown thì các công thức này được lưu ở định dạng ảnh. Do đó cần thêm một bước tiền xử lý để chuyển các công thức ở dạng ảnh này sang công thức ở dạng $\text{\LaTeX}$. Quá trình này được thực hiện thông qua OCR sử dụng mô hình *Gemini 2.5 Flash*⁸. Đối với các file markdown được chuyển từ PDF với công cụ *Marker* thì việc này là không cần thiết do các công thức đã được chuyển sang công thức $\text{\LaTeX}$ với *GPT-4o* và *Gemini 2.5 Flash*. Prompt template được dùng cho phần OCR được trình bày tại phần Phụ lục A.4. Minh hoạ về quá trình trích xuất và chuyển công thức từ dạng ảnh sang công thức dạng $\text{\LaTeX}$ được minh hoạ tại Hình 3.4. Việc chuyển các công thức ở dạng ảnh sang công thức theo định dạng của $\text{\LaTeX}$ nhằm mục đích có thể biểu diễn các công thức ở dạng văn bản cũng như có thể dễ dàng hiểu bởi các mô hình ngôn ngữ lớn từ đó giúp thuận tiện trong việc truy xuất thông tin cũng như sinh ra câu phản hồi một cách trực quan và hiệu quả.

Lưu dữ liệu vào databases. Sau khi đã thực hiện các bước tiền xử lý nêu trên, bao gồm cả xử lý nội dung bảng và các công thức thì lúc này nội dung các bảng đã được mô tả cùng với các sections trước đó được tiếp tục thực hiện chia nhỏ, vì nội dung của một section hoặc nội dung của một bảng có thể rất lớn, do đó việc chia nhỏ này là cần thiết. Quá trình này được thực hiện thông qua *RecursiveCharacterTextSplitter* của LangChain với chunk size là 2048 kí tự và độ trùng lặp giữa các chunk là 256 kí tự. Tổng số lượng section và chunk sau tất cả các bước chia nhỏ dữ liệu được trình bày tại Bảng 3.1.

Ngoài ra, để tăng thêm ngữ cảnh cho các chunk thì mỗi chunk đều được nối thêm tất cả các header của các section mà có chứa chunk này, các header được nối vào đầu chunk. Mục đích của việc này là giúp giữ được ngữ cảnh của thông tin thông qua nội dung của các header, giúp cho phần truy xuất thông tin được hiệu quả hơn. Ngoài ra để tránh nội dung của các header quá dài thì mỗi header được giới hạn lại 256 kí tự, nếu dài hơn 256 kí tự thì chỉ giữ lại 256 kí tự đầu tiên. Minh hoạ cụ thể cho quá trình này được thể hiện ở Hình 3.2.

Thống kê về số lượng header và độ dài header trong các chunk dữ liệu được trình bày tại Bảng 3.2. Trong đó, **# Chunk** là tổng số lượng chunk dữ liệu; **# Chunk w/**

⁸<https://cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash>

Document

ĐỀ ÁN TỔ CHỨC KỶ THI ĐÁNH GIÁ ĐẦU VÀO ĐẠI HỌC TRÊN MÁY TÍNH PHỤC VỤ CHO TUYỂN SINH ĐẠI HỌC (V-SAT) CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ NĂM 2025

I. NỘI DUNG THỰC HIỆN CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ

1. Giới thiệu về Trường Đại học Cần Thơ

1.1. Giới thiệu tổng quan về Trường

Đồng bằng Sông Cửu Long (ĐBSCL), có diện tích khoảng 4 triệu héc-ta đất tự nhiên với trên 17 triệu dân, là vùng sản xuất nông nghiệp lớn nhất cả nước, được ví như vựa lúa của Việt Nam. Ngoài nguồn lương thực, ĐBSCL còn có nguồn lợi về cây ăn quả, thủy hải sản xuất khẩu với trữ lượng lớn và đa dạng về chủng loại. Đây là vùng đất mới trù phú, cảnh quan xinh đẹp, cây trái tốt tươi quanh năm.

...

1.2. Sứ mạng, Tầm nhìn, Giá trị cốt lõi, Triết lý giáo dục, Mục tiêu giáo dục

1.2.1. Sứ mạng

Trường ĐHCT là nơi đào tạo con người tinh hoa trong môi trường học tập khai phóng, nghiên cứu khoa học và chuyển giao công nghệ đương đại, phát triển xã hội thịnh vượng.

Split on headers

Section metadata

<header_1>: ĐỀ ÁN TỔ CHỨC KỶ THI ĐÁNH GIÁ ĐẦU VÀO ĐẠI HỌC TRÊN MÁY TÍNH PHỤC VỤ CHO TUYỂN SINH ĐẠI HỌC (V-SAT) CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ NĂM 2025
<header_2>: I. NỘI DUNG THỰC HIỆN CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ
<header_3>: 1. Giới thiệu về Trường Đại học Cần Thơ
<header_4>: 1.1. Giới thiệu tổng quan về Trường

Section metadata

<header_1>: ĐỀ ÁN TỔ CHỨC KỶ THI ĐÁNH GIÁ ĐẦU VÀO ĐẠI HỌC TRÊN MÁY TÍNH PHỤC VỤ CHO TUYỂN SINH ĐẠI HỌC (V-SAT) CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ NĂM 2025
<header_2>: I. NỘI DUNG THỰC HIỆN CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ
<header_3>: 1. Giới thiệu về Trường Đại học Cần Thơ
<header_4>: 1.2. Sứ mạng, Tầm nhìn, Giá trị cốt lõi, Triết lý giáo dục, Mục tiêu giáo dục
<header_5>: 1.2.1. Sứ mạng

Section content

Đồng bằng Sông Cửu Long (ĐBSCL), có diện tích khoảng 4 triệu héc-ta đất tự nhiên với trên 17 triệu dân, là vùng sản xuất nông nghiệp lớn nhất cả nước, được ví như vựa lúa của Việt Nam. Ngoài nguồn lương thực, ĐBSCL còn có nguồn lợi về cây ăn quả, thủy hải sản xuất khẩu với trữ lượng lớn và đa dạng về chủng loại. Đây là vùng đất mới trù phú, cảnh quan xinh đẹp, cây trái tốt tươi quanh năm.

...

Section content

Trường ĐHCT là nơi đào tạo con người tinh hoa trong môi trường học tập khai phóng, nghiên cứu khoa học và chuyển giao công nghệ đương đại, phát triển xã hội thịnh vượng.

Split content into chunks with
chunk_size = 2048
and *chunk_overlap* = 256 and
prepend headers to chunks

Chunk

ĐỀ ÁN TỔ CHỨC KỶ THI ĐÁNH GIÁ ĐẦU VÀO ĐẠI HỌC TRÊN MÁY TÍNH PHỤC VỤ CHO TUYỂN SINH ĐẠI HỌC (V-SAT) CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ NĂM 2025

I. NỘI DUNG THỰC HIỆN CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ

1. Giới thiệu về Trường Đại học Cần Thơ

1.2. Sứ mạng, Tầm nhìn, Giá trị cốt lõi, Triết lý giáo dục, Mục tiêu giáo dục

1.2.1. Sứ mạng

Trường ĐHCT là nơi đào tạo con người tinh hoa trong môi trường học tập khai phóng, nghiên cứu khoa học và chuyển giao công nghệ đương đại, phát triển xã hội thịnh vượng....

Hình 3.2: Ví dụ quá trình chia nhỏ dữ liệu dựa trên header thành các section, chia nhỏ các section thành các chunk và nối thêm các header để tăng thêm ngữ cảnh cho các chunk

2. CÁC NGÀNH CHƯƠNG TRÌNH ĐÀO TẠO ĐẠI TRÀ

TT	Mã tuyển sinh	Tên ngành (chuyên ngành-nếu có)	Chỉ tiêu	Mã tổ hợp xét tuyển (*)
ĐÀO TẠO GIÁO VIÊN				
1	7140201	Giáo dục Mầm non	150	M01, M06, M11, M05
2	7140202	Giáo dục Tiểu học	100	A00, C01, D01, D03
3	7140204	Giáo dục Công dân	100	C00, C19, D14, D15
4	7140206	Giáo dục Thể chất	100	T00, T01, T06, T10
5	7140209	Sư phạm Toán học	80	A00, A01, B08, D07

Summarize and
describe table content
using **GPT-4o**



Bảng này cung cấp thông tin chi tiết về chương trình tuyển sinh đại học năm 2025 của Đại học Cần Thơ, bao gồm mã tuyển sinh, tên ngành, chỉ tiêu tuyển sinh và mã tổ hợp xét tuyển của từng ngành học.

1. Đào tạo giáo viên: Không có thông tin chi tiết nào.
2. Mã tuyển sinh: 7140201 - Tên ngành: Giáo dục Mầm non, chỉ tiêu: 150, mã tổ hợp xét tuyển: M01, M06, M11, M05.
3. Mã tuyển sinh: 7140202 - Tên ngành: Giáo dục Tiểu học, chỉ tiêu: 100, mã tổ hợp xét tuyển: A00, C01, D01, D03.
4. Mã tuyển sinh: 7140204 - Tên ngành: Giáo dục Công dân, chỉ tiêu: 100, mã tổ hợp xét tuyển: C00, C19, D14, D15.
5. Mã tuyển sinh: 7140206 - Tên ngành: Giáo dục Thể chất, chỉ tiêu: 100, mã tổ hợp xét tuyển: T00, T01, T06, T10.
6. Mã tuyển sinh: 7140209 - Tên ngành: Sư phạm Toán học, chỉ tiêu: 80, mã tổ hợp xét tuyển: A00, A01, B08, D07.

Hình 3.3: ví dụ minh họa quá trình mô tả nội dung của bảng


headers là số lượng chunk có chứa header; **Avg. headers** là số lượng header trung bình trong các chunk; **Avg. headers length** là độ dài trung bình (số lượng kí tự trung bình) của phần header trong các chunk.

Các chunk này sau đó được thêm vào database để hỗ trợ cho phần truy xuất thông tin với RAG, trong đó các embedding vectors cho các chunks được tạo ra thông qua mô hình *BAAI/bge-m3*⁹. *BAAI/bge-m3* là một mô hình nhúng văn bản tiên tiến, phát triển bởi Jianlv Chen và cộng sự [40], hỗ trợ hơn 100 ngôn ngữ và xử lý đầu vào lên đến 8192 tokens. Nó tích hợp ba phương pháp tìm kiếm: tìm kiếm dày đặc, tìm kiếm đa vector và tìm kiếm thưa, giúp truy xuất thông tin hiệu quả từ dữ liệu đa dạng. Mô hình này nổi bật với khả năng tạo nhúng ngữ nghĩa chất lượng cao, phù hợp cho các ứng dụng như hệ thống chatbot hoặc truy xuất thông tin đa ngôn ngữ.

Các embedding vectors của các chunks được lưu ở **Qdrant**¹⁰ vector database và các phần còn lại như nội dung của chunk và metadata như title, mô tả, đường dẫn đến tài liệu, ... được lưu ở **Postgres**. Toàn bộ quy trình thu thập và tiền xử lý dữ liệu được minh họa chi tiết ở Hình 3.1.

⁹<https://huggingface.co/BAAI/bge-m3>

¹⁰<https://qdrant.tech/>



Hình 3.4: Minh hoạ quá trình chuyển các công thức ở dạng ảnh sang $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ bằng OCR với *Gemini 2.5 Flash*

Bảng 3.2: Thống kê số lượng header và độ dài header trong các chunk dữ liệu

# Chunk	# Chunk w/ headers	Avg. headers	Avg. headers length
371	368	2.1	114.6


Trong quá trình xây dựng hệ thống quản lý và truy vấn dữ liệu vector, Qdrant nổi bật như một cơ sở dữ liệu vector mã nguồn mở được thiết kế để đáp ứng các yêu cầu của các ứng dụng AI thời gian thực, đặc biệt trong tìm kiếm tương đồng vector. Được phát triển bằng ngôn ngữ Rust, Qdrant mang lại hiệu suất vượt trội so với ChromaDB — một vector database khác nằm trong top các vector database được sử dụng phổ biến nhất hiện nay. Một trong những ưu điểm chính của Qdrant là khả năng xử lý các tập dữ liệu lớn với hiệu suất ổn định. Qdrant sử dụng thuật toán Hierarchical Navigable Small World (HNSW) được tối ưu hóa, kết hợp với các kỹ thuật lượng tử hóa bất đối xứng, giúp giảm đáng kể kích thước lưu trữ mà vẫn duy trì độ chính xác. Theo báo cáo từ các xu hướng trong AI năm 2024 của Langchain [41] thì Qdrant nằm trong top 5 các vector database được sử dụng phổ biến nhất, việc này cho thấy độ hiệu quả cũng như độ phổ biến của Qdrant.

3.3 Truy xuất thông tin cho hệ thống RAG

Với đầu vào là một câu hỏi từ người dùng, mục đích của bước truy xuất thông tin này là truy xuất các tài liệu có chứa các thông tin liên quan mà có thể được dùng để trả lời câu hỏi của người dùng. Cụ thể hơn, cả các chunk và câu hỏi từ người dùng đều được chuyển thành các embedding vectors sử dụng mô hình nhúng *BAAI/bge-m3*.

Độ tương tự giữa câu hỏi q và tài liệu p được tính thông qua tích vô hướng của các embedding vectors tương ứng theo công thức sau:

$$\text{sim}(q, p) = E(q)^T E(p), \quad (3.1)$$



Hình 3.5: Toàn bộ quy trình xử lý câu hỏi từ người dùng và đưa ra phản hồi của hệ thống

trong đó $E(q)$, $E(p)$ lần lượt là embedding vector của q và p .

Giá trị $\text{sim}(q, p)$ càng lớn thì độ tương tự giữa câu hỏi q và tài liệu p càng lớn và ngược lại.

Với một giá trị k có thể tùy chỉnh được và một vector cần truy xuất q , hệ thống sẽ trả về k vector p_i với $i \in \{1, 2, \dots, k\}$ mà có độ tương tự được tính theo công thức 3.1 với q là lớn nhất. Trong nghiên cứu này, giá trị k được đặt mặc định là 10 trừ khi được chỉ ra cụ thể. Trong nghiên cứu về DPR [10], các tác giả thông qua thực nghiệm đã cho thấy rằng tích vô hướng và khoảng cách Euclidean đạt độ chính xác tương tự nhau và cả hai đều vượt trội hơn so với độ tương tự cosine. Việc này có thể lí giải thông qua việc độ tương tự cosine chuẩn hoá tích vô hướng của hai vector theo độ dài do đó có thể làm mất các thông tin về biên độ của các embedding vector. Nghiên cứu này áp dụng công thức khoảng cách tính bằng tích vô hướng để đảm bảo các thông tin truy xuất được là hữu ích và chính xác nhất.

3.3.1 Query expansion

Để tăng thêm độ chính xác trong việc truy xuất ra được tối đa các tài liệu có liên quan, nghiên cứu này áp dụng kỹ thuật Query expansion (hay Query rewriting) để tạo ra các câu hỏi có liên quan và gần như tương tự như câu hỏi gốc với mục đích tăng sự đa dạng và ngữ cảnh cho việc truy xuất. Cụ thể, trong nghiên cứu này, với mỗi truy vấn q sẽ tạo ra thêm 3 câu truy vấn tương tự, các câu truy vấn được tạo ra kết hợp với câu truy vấn gốc được dùng cho quá trình truy xuất với RAG. Mô hình được sử dụng cho việc sinh thêm truy vấn liên quan trong nghiên cứu này là *Gemini 2.5 Flash*. Prompt template sử dụng cho phần này được trình bày tại Phụ lục A.2. Một số ví dụ của phần này được trình bày tại Bảng 3.3, từ các ví dụ có thể thấy rằng việc sinh thêm các câu hỏi tương tự giúp làm rõ ý định cũng như ngữ cảnh cho các câu hỏi gốc có nội dung mơ hồ, chưa rõ ràng hoặc thiếu ngữ cảnh.

Thuật toán Reciprocal rank fusion. Vì việc truy xuất lúc này được thực hiện trên nhiều truy vấn (bao gồm cả truy vấn gốc cùng với 3 truy vấn mới tương tự được tạo ra) do đó số lượng tài liệu truy xuất được sẽ vượt quá k tài liệu, lúc này thuật toán *Reciprocal rank fusion* - *RRF* được áp dụng để kết hợp kết quả truy xuất được

Bảng 3.3: Một số ví dụ về các câu hỏi liên quan được tạo ra dựa trên câu hỏi gốc cho kỹ thuật Query expansion

STT	Câu hỏi gốc	Các câu hỏi được tạo ra
1	Thời gian xét học bạ của trường?	- Thời gian xét tuyển học bạ của Đại học Cần Thơ là khi nào? - Khi nào thì trường Đại học Cần Thơ bắt đầu xét tuyển học bạ? - Thời gian nộp hồ sơ xét học bạ của Đại học Cần Thơ năm 2025?
2	Điểm học bạ 27,1 có thể đậu ngành luật không?	- Ngành Luật của CTU có xét tuyển bằng điểm học bạ không? - Với 27,1 điểm học bạ, tôi có cơ hội trúng tuyển ngành Luật tại CTU không? - Điểm chuẩn học bạ ngành Luật của CTU năm 2025 là bao nhiêu?
3	Xét học bạ CTU xét 6 học kỳ hay sao?	- Xét học bạ vào CTU thì tính điểm bao nhiêu học kỳ? - Đại học Cần Thơ xét tuyển bằng học bạ dựa trên kết quả học tập của mấy học kỳ? - Phương thức xét tuyển học bạ của CTU yêu cầu điểm trung bình của bao nhiêu học kỳ?


của nhiều queries lại với nhau thành một danh sách có thứ hạng duy nhất. Công thức của RRF được biểu diễn như sau:

$$\text{RRF}(d) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(d)}, \quad (3.2)$$

trong đó d là một mẫu tài liệu, R là tập các bộ truy xuất, k là một hằng số thường được lấy bằng 60 và $\text{rank}_r(d)$ là thứ hạng của tài liệu d trong bộ truy xuất r . Minh hoạ cho việc tổng hợp các tài liệu truy xuất được với nhiều truy vấn được thể hiện ở Hình 3.6.

Việc lựa chọn giá trị $k = 60$ trong RRF bắt nguồn từ các nghiên cứu thực nghiệm, đặc biệt từ công trình của Cormack và cộng sự [42], trong đó giá trị này được chứng minh là mang lại hiệu quả tối ưu trong nhiều ngữ cảnh truy xuất thông tin. Hằng số k đóng vai trò điều chỉnh mức độ ảnh hưởng của các tài liệu có thứ hạng thấp. Với $k = 60$, các tài liệu ở vị trí cao (ví dụ, thứ hạng 1 hoặc 2) được ưu tiên rõ rệt thông qua giá trị $\text{RRF}(d)$ lớn (theo phương trình 3.2), trong khi các tài liệu ở thứ hạng thấp (ví dụ, thứ hạng 1000) có đóng góp rất nhỏ, gần bằng 0. Điều này giúp RRF tập trung vào các tài liệu có mức độ liên quan cao, đồng thời vẫn cho phép các tài liệu ở vị trí trung bình (ví dụ như từ 20 cho đến 100) đóng góp một phần vào kết quả cuối cùng mà không có khoảng cách quá lớn so với các thứ hạng 1 hay 2. Giá trị $k = 60$ được xem là một lựa chọn tổng quát, phù hợp với nhiều tập dữ liệu và ứng dụng mà không cần tinh chỉnh thêm, nhờ khả năng cân bằng giữa độ chính xác và tính đa dạng của danh sách thứ hạng.

Thuật toán *Reciprocal Rank Fusion* nổi bật với độ hiệu quả cao trong việc kết hợp kết quả truy xuất từ nhiều bộ truy xuất khác nhau hoặc nhiều lần truy xuất với các truy vấn khác nhau trong hệ thống RAG, nhờ cơ chế đơn giản dựa trên thứ hạng thay



Hình 3.6: Minh họa việc tổng hợp các tài liệu khi thực hiện truy xuất trên nhiều truy vấn với thuật toán *Reciprocal rank fusion*

vì điểm số tuyệt đối, giúp tránh việc phải chuẩn hóa và giảm thiểu sự khác biệt trong các công thức tính điểm khác nhau giữa các mô hình như sparse (BM25) và dense (embedding).

3.3.2 Reranking

Reranking là một kỹ thuật quan trọng trong các hệ thống truy xuất thông tin, đặc biệt là trong các hệ thống RAG, nhằm sắp xếp lại thứ tự về độ liên quan của các tài liệu truy xuất được. Trong một hệ thống truy xuất hai giai đoạn, giai đoạn đầu tiên sử dụng một phương pháp truy xuất nhanh, chẳng hạn như tìm kiếm dựa trên embedding vectors để thu thập một tập hợp lớn các tài liệu ứng viên. Sau đó, giai đoạn thứ hai sử dụng một mô hình reranker, thường là một cross-encoder, để đánh giá lại và sắp xếp lại các tài liệu này dựa trên độ liên quan so với truy vấn, từ đó đưa các tài liệu phù hợp nhất lên đầu danh sách. Kỹ thuật này đặc biệt hữu ích trong các hệ thống RAG, nơi chất lượng của các tài liệu được truy xuất ảnh hưởng trực tiếp đến chất lượng của câu trả lời do mô hình ngôn ngữ lớn tạo ra.

Trong nghiên cứu này, reranking được áp dụng sau khi thực hiện truy xuất ban đầu bằng mô hình embedding *BAAI/bge-m3* và sử dụng kỹ thuật query expansion kết hợp với Reciprocal Rank Fusion (RRF) để tạo ra một danh sách các tài liệu ứng viên. Cụ thể, với mỗi truy vấn gốc sẽ tạo ra ba truy vấn tương tự, thực hiện truy xuất top- k tài liệu cho từng truy vấn (trong nghiên cứu này, $k = 10$), sau đó sử dụng RRF để kết hợp các kết quả thành một danh sách xếp hạng duy nhất. Các tài liệu này sau đó được đưa vào mô hình reranker để tính điểm liên quan (relevance score) cho từng cặp (query, chunk), và được sắp xếp lại dựa trên điểm số để chọn ra top- k tài liệu liên quan nhất. Quá trình này giúp sắp xếp lại các tài liệu theo độ liên quan so với câu hỏi, đảm bảo rằng các tài liệu liên quan nhất được ưu tiên sắp ở các vị trí đầu tiên trong danh sách các tài liệu liên quan, giảm thiểu ảnh hưởng từ hiện tượng *Lost in the middle* [37] thường được tìm thấy ở các mô hình ngôn ngữ lớn ngày nay.

Để thực hiện reranking, nghiên cứu này sử dụng mô hình *BAAI/bge-reranker-v2-*

$m3^{11}$, một mô hình reranker đa ngôn ngữ nhẹ được phát triển bởi Beijing Academy of Artificial Intelligence (BAAI). Mô hình này được tinh chỉnh từ mô hình embedding *BAAI/bge-m3* [40], với khả năng xử lý hiệu quả nhiều ngôn ngữ, bao gồm tiếng Việt. Ngoài ra, mô hình này được thiết kế để có tốc độ inference nhanh và dễ triển khai, đáp ứng tốt các yêu cầu về hiệu suất của hệ thống tư vấn tuyển sinh.

3.4 Sinh câu trả lời với mô hình ngôn ngữ lớn

Sau khi đã truy xuất được các tài liệu liên quan ở các bước trên, quá trình sinh ra câu trả lời được thực hiện bằng cách nối các tài liệu truy xuất được cùng với câu hỏi của người dùng và đưa vào một mô hình ngôn ngữ lớn. Mô hình được sử dụng trong nghiên cứu này cho việc sinh câu trả lời là *Gemini 2.5 Flash* với prompt template được dùng được trình bày tại Phụ lục A.1. Quy trình đầy đủ từ bước xử lý câu hỏi người dùng, truy xuất tài liệu liên quan và sinh ra câu phản hồi được minh họa cụ thể tại Hình 3.5.

Để các mô hình ngôn ngữ lớn có thể dễ dàng phân biệt nội dung chính của thông tin liên quan và các metadata thì mỗi tài liệu liên quan trong ngữ cảnh được biểu diễn ở định dạng tương tự với định dạng XML, cụ thể như sau:

```
<Document title="{{ document_title }}" url="{{ document_url }}" description="{{ document_description }}">{{ Document 1 }}</Document>

<Document title="{{ document_title }}" url="{{ document_url }}" description="{{ document_description }}">{{ Document 2 }}</Document>

...
```

Việc biểu diễn các tài liệu ở định dạng XML giúp các mô hình ngôn ngữ lớn có thể trích xuất một cách dễ dàng và chính xác nội dung của tài liệu cũng như các metadata như title hoặc url của tài liệu.

Nhiệm vụ chính của mô hình ngôn ngữ lớn lúc này tập trung vào việc trích xuất các thông tin mà có thể được dùng để trả lời câu hỏi của người dùng cũng như liên kết các thông tin liên quan trong trường hợp các thông tin nằm ở những tài liệu khác nhau. Ngoài ra mô hình cũng được yêu cầu trích xuất các đường dẫn liên quan của những tài liệu đã được dùng để trả lời câu hỏi nhằm cung cấp thêm đường dẫn đến các tài liệu liên quan cho người dùng.

¹¹<https://huggingface.co/BAAI/bge-reranker-v2-m3>

CHƯƠNG 4

THỰC NGHIỆM

4.1 Môi trường thực nghiệm

Tất cả các thực nghiệm trong bài nghiên cứu này đều được thực hiện trên hệ thống có phần cứng bao gồm CPU Intel i7-14700K (28) @ 5.500GHz, RAM 32GB, GPU NVIDIA RTX 4060 (16GB VRAM). Hệ thống chạy trên hệ điều hành Ubuntu 24.04.2. Phiên bản Python được dùng là 3.12.

4.2 Dữ liệu thực nghiệm

Phần dữ liệu được dùng cho phần thực nghiệm bao gồm hai loại là *dữ liệu tổng hợp* và *dữ liệu thu thập*. Trong đó *dữ liệu tổng hợp* được tổng hợp dựa trên các tài liệu đã được xử lý cho RAG sử dụng mô hình ngôn ngữ lớn và *dữ liệu thu thập* được thu thập từ một nhóm chat cộng đồng về tư vấn tuyển sinh đại học của Đại học Cần Thơ năm 2025.

4.2.1 Dữ liệu tổng hợp

Vì các tài liệu thu thập và xử lý được chỉ bao gồm các tài liệu chứa thông báo, thông tin hay quy định nên không có bộ dữ liệu để đánh giá độ hiệu quả của hệ thống. Do đó, bài nghiên cứu thực hiện tổng hợp câu hỏi dựa trên các tài liệu này để dùng cho việc đánh giá hệ thống.

Cụ thể, quy trình tổng hợp câu hỏi từ các tài liệu được thực hiện như sau. Đầu tiên nhóm các chunks theo section và sắp xếp theo thứ tự xuất hiện của mỗi chunk trong section, các chunks của mỗi section được xử lý theo batch (với số lượng chunks mỗi batch là 2), nội dung của mỗi batch là nội dung của các chunks trong batch đó được nối lại với nhau. Sau đó sử dụng mô hình *GPT-4o* và yêu cầu dựa trên nội dung của mỗi batch để sinh ra các câu hỏi mà các câu hỏi này có thể được trả lời dựa trên phần nội dung được cung cấp, đồng thời mô hình được sử dụng (cụ thể là *GPT-4o*) cũng được yêu cầu trích dẫn thêm các chunks mà cần thiết để có thể trả lời câu hỏi được tạo ra, việc này nhằm mục đích để có thể đánh giá độ hiệu quả của phần truy xuất (retriever) cũng như phần reranking với các chỉ số Recall, MRR, MAP và NDCG. Prompt template được dùng cho phần này được trình bày tại Phụ lục A.5.

Tập dữ liệu này được tham chiếu đến với tên *Synthesized*. Các thông số chi tiết về tập dữ liệu được trình bày tại Bảng 4.1.

Bảng 4.1: Chi tiết về các tập dữ liệu cho phần thực nghiệm

Tập dữ liệu	Phương pháp thu thập	Số câu hỏi
<i>Synthesized</i>	Tổng hợp dựa trên nội dung của các tài liệu	258
<i>Collected</i>	Trích xuất câu hỏi từ các đoạn tin nhắn	300

4.2.2 Dữ liệu thu thập

Để đánh giá thêm độ hiệu quả của hệ thống đối với các câu hỏi mang tính đa dạng và thực tế, bài nghiên cứu thực hiện tổng hợp các tin nhắn từ một nhóm cộng đồng về tư vấn tuyển sinh đại học của Đại học Cần Thơ năm 2025. Các câu hỏi được tổng hợp từ đây sẽ đảm bảo được sự đa dạng, thực tế, và có thể có các câu hỏi mà không thể trả lời với các thông tin hiện có, ví dụ các thông tin về điểm chuẩn của từng ngành mà chưa được công bố.

Bảng 4.2: Một số ví dụ về các câu hỏi tổng hợp được của tập dữ liệu *Collected*

STT	Nội dung
1	Ngành sư phạm mầm non cần bao nhiêu điểm? Có xét học bạ không?
2	Điểm học bạ 27,1 có thể đậu ngành luật không?
3	CTU có xét học bạ cho tất cả các trường không?
4	Điểm thi bao nhiêu thì đậu ngành luật?
5	Sư phạm thể chất năm nay lấy bao nhiêu điểm?
6	Điểm 296 B00 có vào được ngành hóa học không?
7	Khối A00, A01 với 24 điểm có đậu được ngành quản trị nào không?
8	Ngành kỹ thuật điện tử viễn thông năm nay lấy cao không?
9	Ngành CNTT lấy bao nhiêu điểm

Các tin nhắn thu thập được đều được lọc bỏ đi các thông tin về danh tính để đảm bảo giữ quyền riêng tư của người gửi và chỉ giữ lại nội dung tin nhắn cùng với thời gian gửi. Các tin nhắn sau đó được sắp xếp theo thời gian gửi. Tuy nhiên, các nội dung tin nhắn không phải lúc nào cũng là câu hỏi, do đó cần có thêm bước xử lý để lọc ra các câu hỏi liên quan đến các vấn đề về tuyển sinh. Cụ thể, các tin nhắn được nhóm lại với nhau và xử lý theo batch, với mỗi batch chứa 30 tin nhắn liên tiếp nhau. Sau đó, các tin nhắn này được trích xuất với mô hình *GPT-4o* để sinh ra các câu hỏi có trong nội dung của batch được xử lý, prompt template được dùng được trình bày tại Phụ lục A.6.

Vì các dữ liệu thu thập được này không hề có các chunk tham chiếu như **dữ liệu tổng hợp** nên dữ liệu này chỉ được dùng ở phần đánh giá phần phản hồi của hệ thống, cụ thể là các chỉ số Faithfulness, Answer relevance và Context Relevance.

Tập dữ liệu này được tham chiếu đến với tên *Collected*. Các thông số chi tiết về tập dữ liệu được trình bày tại Bảng 4.1. Một số câu hỏi ví dụ được trình bày tại Bảng 4.2.

Quy trình các bước tiền xử lý dữ liệu cho RAG cùng với quy trình truy xuất thông tin cho RAG đã được trình bày chi tiết lần lượt tại mục 3.2 và mục 3.3.

4.3 Kết quả đánh giá thành phần truy xuất

Việc đánh giá các hệ thống RAG thông thường sẽ bao gồm hai phần chính: đánh giá thành phần truy xuất và đánh giá câu phản hồi của mô hình. Các kết quả đánh giá thành phần truy xuất với Recall, MRR, MAP và NDCG trên tập dữ liệu *Synthesized* lần lượt được trình bày Bảng 4.3, Bảng 4.4, Bảng 4.5 và Bảng 4.6. Trong đó **Baseline** tương ứng với việc không áp dụng Query expansion lẫn Reranking, **Query expansion** tương ứng với có áp dụng query expansion (với số query mới được tạo ra là 3), **Reranking** tương ứng với có áp dụng reranking, **Query expansion + Reranking** tương ứng với

áp dụng cả hai kỹ thuật trên và giá trị k là giới hạn số lượng tài liệu liên quan truy xuất được. Biểu đồ so sánh kết quả trên các chỉ số đánh giá thành phần truy xuất đối với các giá trị k khác nhau được thể hiện chi tiết tại Hình 4.1.

Bảng 4.3: Kết quả đánh giá Recall của thành phần truy xuất

Method	$k = 1$	$k = 3$	$k = 5$	$k = 10$
Baseline	0.0407	0.1453	0.3178	0.7481
Query expansion	0.0349	0.1376	0.3159	0.7616
Reranking	0.6318	0.7326	0.7461	0.7481
Query expansion + Reranking	0.6240	0.7384	0.7616	0.7713

Bảng 4.4: Kết quả đánh giá MRR của thành phần truy xuất

Method	$k = 1$	$k = 3$	$k = 5$	$k = 10$
Baseline	0.0426	0.0879	0.1274	0.1839
Query expansion	0.0388	0.0859	0.1255	0.1837
Reranking	0.6589	0.6977	0.7002	0.7008
Query expansion + Reranking	0.6512	0.6957	0.6998	0.7006

Bảng 4.5: Kết quả đánh giá MAP của thành phần truy xuất

Method	$k = 1$	$k = 3$	$k = 5$	$k = 10$
Baseline	0.0407	0.0833	0.1216	0.1809
Query expansion	0.0349	0.0785	0.1186	0.1798
Reranking	0.6318	0.6838	0.6873	0.6876
Query expansion + Reranking	0.6240	0.6831	0.6891	0.6906

Bảng 4.6: Kết quả đánh giá NDCG của thành phần truy xuất

Method	$k = 1$	$k = 3$	$k = 5$	$k = 10$
Baseline	0.0426	0.1005	0.1715	0.3120
Query expansion	0.0388	0.0957	0.1689	0.3142
Reranking	0.6589	0.6997	0.7054	0.7062
Query expansion + Reranking	0.6512	0.7004	0.7102	0.7133

Nhận xét. Dựa trên các kết quả thực nghiệm, có thể thấy rằng cả bốn chỉ số đánh giá đều cho kết quả khá thấp với **Baseline** và **Query expansion** với các giá trị k nhỏ ($k = 1, 3, 5$). Với giá trị k lớn hơn ($k = 10$) thì các chỉ số đã được cải thiện đáng kể.

Với **Query expansion**, việc áp dụng query expansion chỉ giúp cải thiện giá trị Recall với giá trị $k = 10$. Tuy nhiên khi kết hợp với reranking (**Query expansion +**

Reranking) lại đạt được giá trị Recall cao nhất trong bốn phương pháp được sử dụng (chỉ ngoại trừ trường hợp $k = 1$). Mặc dù sự cải thiện là không quá đáng kể, tuy nhiên vẫn cho thấy được việc áp dụng query expansion giúp làm tăng khả năng truy xuất được các thông tin chính xác hơn.

Với **Reranking**, áp dụng reranking đã cải thiện một cách đáng kể so với cả **Baseline** và **Query expansion**, với Recall, việc cải thiện là rõ rệt với các giá trị $k = 1$ và $k = 3$ tương ứng với tăng Recall từ 0.0407 lên 0.6318 với $k = 1$ và tăng từ 0.1453 lên 0.7326 với $k = 3$ so với **Baseline**. Đặc biệt, với các chỉ số tập trung vào việc đánh giá độ hiệu quả của thành phần reranking bao gồm MRR, MAP và NDCG thì việc cải thiện so với **Baseline** là khá đáng kể trên cả các giá trị $k = 1, 3, 5$ lẫn giá trị $k = 10$, kết quả này minh chứng cho sự hiệu quả của thành phần reranking giúp ưu tiên các tài liệu liên quan đến câu hỏi nhất lên các vị trí đầu tiên.

Kết luận. Việc kết hợp cả query expansion và reranking chỉ mang lại kết quả tương đối so với chỉ áp dụng reranking trên các chỉ số MRR, MAP và NDCG nhưng lại có sự cải thiện đáng kể trên chỉ số Recall. Do đó, xét về mặt tổng thể, **Query expansion + Reranking** mang lại sự cải thiện so với các phương pháp còn lại bao gồm **Baseline**, **Query expansion** và **Reranking** cho thấy độ hiệu quả khi áp dụng cả hai kỹ thuật query expansion và reranking trong hệ thống RAG. Ngoài ra, sự khác biệt về kết quả trên các chỉ số đối với giá trị $k = 5$ và $k = 7$ là không quá lớn (Hình 4.1), do đó khi triển khai trong thực tế, tùy vào nhu cầu về độ hiệu quả và tốc độ mà có thể chọn giá trị k phù hợp. Cụ thể, trong trường hợp muốn hệ thống phản hồi nhanh thì có thể chọn các giá trị k nhỏ như $k = 5$ hoặc $k = 10$. Trong trường hợp ưu tiên về độ chính xác trong câu trả lời và thời gian phản hồi của hệ thống không phải là yếu tố quan trọng nhất thì có thể chọn các giá trị k lớn hơn như $k = 10$ hoặc $k = 20$.


4.4 Kết quả đánh giá phần phản hồi

Kết quả đánh giá về phần phản hồi của hệ thống với các chỉ số Faithfulness, Answer relevance và Context relevance trên hai tập dữ liệu *Synthesized* và *Collected* được trình bày ở Bảng 4.7. Các kết quả này được đánh giá trên phương pháp **Query expansion + Reranking**. Mô hình ngôn ngữ lớn được dùng để làm mô hình đánh giá là *GPT-4o-mini*, mô hình embedding là *text-embedding-ada-002*, cả hai mô hình này đều đến từ OpenAI. Giá trị k (giới hạn về số lượng ngữ cảnh truy xuất được) được dùng là $k = 5$.

Bảng 4.7: Kết quả đánh giá trên phản hồi của hệ thống với RAGAS

Data	Faithfulness	Answer relevance	Context Relevance
Synthesized	0.7923	0.7518	0.9060
Collected	0.6454	0.5102	0.7358

Nhận xét. Đối với tập dữ liệu *Synthesized*, có thể thấy cả ba chỉ số là tương đối cao, đặc biệt với Context relevance đạt được 0.9060 cũng như Faithfulness là 0.7923. Các kết quả này cho thấy độ hiệu quả của thành phần truy xuất trong việc truy xuất các thông tin liên quan và độ tin cậy cao trong câu trả lời của mô hình trong việc đưa ra câu trả lời đáng tin cậy dựa vào các thông tin liên quan trong ngữ cảnh, giảm thiểu tối



Hình 4.1: Biểu đồ so sánh kết quả trên các chỉ số đánh giá thành phần truy xuất đối với các giá trị k khác nhau của phương pháp **Query expansion + Reranking**

đa tình trạng ảo tưởng (hallucination) của mô hình. Ngoài ra kết quả đối với Answer relevance cũng tương đối cao với 0.7518 cho thấy các câu trả lời được tạo ra liên quan đến câu hỏi của người dùng và giải đáp được các thắc mắc từ người dùng một cách trực quan dễ hiểu mà không chứa quá nhiều các thông tin không liên quan trong câu trả lời.

Tuy nhiên, đối với tập dữ liệu *Collected*, cả ba chỉ số đánh giá đều có phần giảm so với tập dữ liệu *Synthesized*, trong đó đáng kể nhất là Answer relevance với chỉ 0.5102. Lí giải cho việc này có hai lí do. Đầu tiên là do tập dữ liệu *Synthesized* được tổng hợp bằng cách tạo ra các câu hỏi dựa trên các tài liệu nên hầu hết các câu hỏi được tạo ra là có thể trả lời được. Lí do thứ hai là với các câu hỏi trong tập dữ liệu *Collected*, vì nguồn dữ liệu đến từ một nhóm chat từ cộng đồng, do đó sẽ có sự đa dạng cao hơn cũng như chứa khá nhiều các câu hỏi mà không thể trả lời hoặc khó trả lời được một cách hoàn chỉnh và giải đáp được hoàn toàn thắc mắc từ người dùng.

4.5 Đánh giá về thời gian phản hồi của hệ thống

Các đánh giá về thời gian phản hồi của hệ thống được trình bày tại Bảng 4.8. Trong đó *Total response time* là tổng thời gian từ lúc bắt đầu xử lý câu hỏi cho đến khi đưa ra câu trả lời hoàn chỉnh.

Nhận xét. Với các thực nghiệm trong bài nghiên cứu này, việc áp dụng query expansion làm tăng đáng kể thời gian phản hồi của toàn bộ hệ thống, cụ thể thời gian phản hồi trung bình tăng từ 2.534 lên 3.806 so với **Baseline**. Lí do cho hiện tượng này đến từ việc sử dụng mô hình *Gemini 2.5 Flash* cho việc mở rộng câu hỏi, mặc dù đây là một trong những mô hình có độ trễ thấp nhất nhưng việc sử dụng mô hình thông qua

Bảng 4.8: Kết quả đánh giá về thời gian phản hồi của hệ thống với $k = 10$. Các kết quả được thể hiện ở dạng $\text{mean} \pm \text{std}$ với mean là giá trị trung bình và std là độ lệch chuẩn

Method	Total response time (seconds)
Baseline	2.534 ± 0.811
Query expansion	3.806 ± 0.986
Reranking	2.689 ± 0.874
Query expansion + Reranking	4.741 ± 1.460

API vẫn mang lại độ trễ nhất định. Trái ngược với **Query expansion**, **Reranking** cải thiện kết quả trên các chỉ số đánh giá tương đối lớn nhưng chỉ làm tăng thời gian phản hồi trung bình không quá nhiều, chỉ tăng khoảng 0.155 giây so với **Baseline**. Việc áp dụng cả query expansion và reranking làm tăng đáng kể thời gian phản hồi trung bình của hệ thống từ 2.534 lên 4.741 giây.

4.6 Thảo luận

Một phần hạn chế của nghiên cứu này là dữ liệu đánh giá chủ yếu đến từ việc sinh tổng hợp với các mô hình ngôn ngữ lớn và thu thập dữ liệu từ cộng đồng. Do đó, các số liệu thực nghiệm trong nghiên cứu này chỉ mang tính tương đối. Ngoài ra, do giới hạn về chi phí nên số lượng câu hỏi được dùng để đánh giá hệ thống vẫn còn tương đối ít và thiếu sự đa dạng.

Về các chỉ số đánh giá được dùng cho phần đánh giá phản hồi của hệ thống (Faithfulness, Answer relevance và Context relevance) được sử dụng dựa trên framework RAGAS. Tuy nhiên, RAGAS áp dụng các prompt được thiết kế sẵn, việc này có thể làm giảm khả năng thích ứng của mô hình ngôn ngữ lớn được dùng cho phần đánh giá [16] dẫn đến làm giảm các kết quả đánh giá. Các hướng nghiên cứu trong tương lai có thể xem xét áp dụng các phương pháp thay thế khác như ARES [16] hoặc thực hiện việc đánh giá một cách thủ công.

Ngoài các kỹ thuật, phương pháp, cũng như cách tiếp cận được giới thiệu và áp dụng trong nghiên cứu này, vẫn còn khá nhiều các phương pháp cũng như cách tiếp cận mang lại hiệu quả tối ưu hơn, tuy nhiên có phần vượt ngoài phạm vi của nghiên cứu này do đó chỉ được thảo luận ở đây. Điển hình có thể kể đến như Agentic RAG, một cách tiếp cận mạnh mẽ hơn mà trong đó một hệ thống Agent chịu trách nhiệm thực hiện các tác vụ một cách tự động thông qua các công cụ và tài nguyên được cung cấp, từ bước lên kế hoạch, tinh chỉnh lại câu hỏi, truy xuất tài liệu liên quan và sinh ra câu trả lời, việc truy xuất thông tin có thể thực hiện nhiều hơn một lần và được lặp đi lặp lại cho đến khi có được các thông tin cần thiết để đưa ra câu trả lời cho câu hỏi.

CHƯƠNG 5

KẾT LUẬN VÀ ĐỀ XUẤT HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Luận văn này đã trình bày quá trình nghiên cứu và phát triển một hệ thống tư vấn tuyển sinh thông minh cho Đại học Cần Thơ, dựa trên mô hình hội thoại tự động sử dụng kỹ thuật Retrieval-Augmented Generation. Hệ thống được thiết kế nhằm cung cấp thông tin tuyển sinh chính xác, kịp thời và đáng tin cậy cho thí sinh và phụ huynh, đồng thời giảm tải áp lực cho đội ngũ tư vấn truyền thống của nhà trường.

Hệ thống đã được xây dựng thành công với khả năng xử lý các câu hỏi liên quan đến tuyển sinh năm 2025 của Đại học Cần Thơ, từ các thông tin về phương thức xét tuyển, tổ hợp môn, chỉ tiêu, đến các quy định và thông báo liên quan. Việc áp dụng kỹ thuật RAG, kết hợp với các mô hình ngôn ngữ lớn hiện đại như *GPT-4o*, *Gemini 2.5 Flash* và các kỹ thuật tối ưu như Query Expansion và Reranking đã giúp hệ thống đạt được hiệu suất vượt trội so với các phương pháp cơ bản.

Quá trình thu thập và tiền xử lý dữ liệu cũng là một phần quan trọng của nghiên cứu. Dữ liệu từ các nguồn đa dạng như trang web của trường (định dạng HTML) và tài liệu PDF đã được xử lý và chuyển đổi thành định dạng markdown thông qua các công cụ như Firecrawl và Marker. Các bảng và công thức toán học được xử lý một cách hiệu quả bằng cách sử dụng mô hình *GPT-4o* và *Gemini 2.5 Flash* để mô tả nội dung bảng và chuyển đổi công thức từ ảnh sang định dạng LaTeX . Việc lưu trữ dữ liệu vào cơ sở dữ liệu vector Qdrant và Postgres, cùng với việc sử dụng mô hình nhúng *BAAI/bge-m3*, đã đảm bảo hiệu quả trong truy xuất thông tin và hỗ trợ quá trình sinh câu trả lời.

Nghiên cứu cũng trình bày phương pháp thu thập và tổng hợp dữ liệu để đánh giá độ hiệu quả của cả thành phần truy xuất lẫn thành phần sinh của hệ thống, trong đó tập trung vào việc ứng dụng các mô hình ngôn ngữ lớn mạnh mẽ để tự động hoá trong việc tổng hợp dữ liệu dựa trên nội dung của các tài liệu thu thập được lẫn trích xuất dữ liệu từ các dữ liệu thô thu thập được từ một nhóm tư vấn tuyển sinh từ cộng đồng.

5.2 Đề xuất hướng phát triển

Trong tương lai, có thể nghiên cứu thêm một số cách tiếp cận khác phù hợp xu hướng và hiệu quả hơn như Agentic RAG, trong đó hệ thống Agent thực hiện một cách tự động hoá hầu hết các tác vụ, từ nhận truy vấn từ người dùng, lên kế hoạch, tiền xử lý câu hỏi từ người dùng, các bước truy xuất thông tin, hậu xử lý các thông tin truy xuất được và cuối cùng là đưa câu phản hồi đến cho người dùng. Hướng tiếp cận này giúp tránh các logic cài đặt cứng nhắc và để hệ thống Agent tùy biến theo từng trường hợp cụ thể.

Trong nghiên cứu này thì tất cả các quy trình từ bước chọn lọc tài liệu, thu thập dữ liệu cho đến tiền xử lý dữ liệu cho hệ thống RAG đều được thực hiện một cách thủ công. Các nghiên cứu trong tương lai có thể xem xét việc đề xuất một quy trình chọn lọc, thu thập, tiền xử lý và thêm các dữ liệu mới này vào cơ sở dữ liệu một cách tự động. Việc này giúp cho việc tích hợp thêm dữ liệu trong tương lai diễn ra một cách nhanh chóng, dễ dàng và hiệu quả hơn. Ví dụ như tự động thu thập thông tin đề án

tuyển sinh của trường trong các năm tuyển sinh tiếp theo; cập nhật các thông tin, các thông báo hay quy định mới từ các cổng thông tin chính thức của trường theo hàng tuần hoặc hàng ngày để đảm bảo hệ thống luôn có nguồn dữ liệu mới nhất và được cập nhật một cách liên tục.

Ngoài ra, một hướng khác trong việc mở rộng hệ thống là tích hợp thêm một Agent giúp tự động hoá việc tra cứu và trích xuất các thông tin từ Internet để truy xuất các thông tin liên quan đến chương trình tuyển sinh nói riêng và các thông tin về Đại học Cần Thơ nói chung trong trường hợp các thông tin tài liệu hiện có của hệ thống chưa thể giải đáp thắc mắc từ người dùng. Việc này cũng giúp tra cứu các thông tin vừa mới được cập nhật thông qua Internet mà chưa kịp được thu thập và thêm vào hệ thống hiện có.

Một hướng phát triển tiềm năng khác là tích hợp thêm một thành phần để phân tích và xử lý trên các cuộc đối thoại từ người dùng để tổng hợp tất cả các câu hỏi từ người dùng có liên quan đến các vấn đề về tuyển sinh đại học cũng như các vấn đề khác như quy định, quy trình mà chưa thể trả lời với các thông tin hiện có. Từ đó, dựa trên những thắc mắc mà chưa thể trả lời này để có thể xem xét việc ban hành các thông báo, quy định, quy trình mới nhằm giải đáp được các thắc mắc này trong tương lai.

TÀI LIỆU THAM KHẢO

- [1] “Bùng nổ chatbot ai tư vấn xét tuyển đại học,” <https://tuoitre.vn/bung-no-chatbot-ai-tu-van-xet-tuyen-dai-hoc-20250711230350267.htm>, accessed: 2025-07-21.
- [2] “Trường đại học ứng dụng chatbot ai để tuyển sinh,” <https://giaoduc.edu.vn/truong-dai-hoc-ung-dung-chatbot-ai-de-tuyen-sinh/>, accessed: 2025-07-21.
- [3] “Tp hồ chí minh: Nhiều trường đại học dùng chatbot ai tư vấn xét tuyển,” <https://hanoimoi.vn/tp-ho-chi-minh-nhieu-truong-dai-hoc-dung-chatbot-ai-tu-van-xet-tuyen-709221.html>, accessed: 2025-07-21.
- [4] J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, D. Almeida, J. Altenschmidt, S. Altman, S. Anadkat *et al.*, “Gpt-4 technical report,” *arXiv preprint arXiv:2303.08774*, 2023.
- [5] G. Team, R. Anil, S. Borgeaud, J.-B. Alayrac, J. Yu, R. Soricut, J. Schalkwyk, A. M. Dai, A. Hauth, K. Millican *et al.*, “Gemini: a family of highly capable multimodal models,” *arXiv preprint arXiv:2312.11805*, 2023.
- [6] X. Grok, “Beta—the age of reasoning agents| xai, 2025,” <https://x.ai/news/grok-3>, accessed: 2025-07-21.
- [7] —, “Grok 4,” <https://x.ai/news/grok-4>, accessed: 2025-07-21.
- [8] Anthropic, “Introducing the next generation of claude,” <https://www.anthropic.com/news/claude-3-family>, accessed: 2025-07-21.
- [9] —, “Introducing claude 4,” <https://www.anthropic.com/news/claude-4>, accessed: 2025-07-21.
- [10] V. Karpukhin, B. Oguz, S. Min, P. S. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, “Dense passage retrieval for open-domain question answering.” in *EMNLP (1)*, 2020, pp. 6769–6781.
- [11] Y. Luan, J. Eisenstein, K. Toutanova, and M. Collins, “Sparse, dense, and attentional representations for text retrieval. corr abs/2005.00181 (2020),” *arXiv preprint arXiv:2005.00181*, 2020.
- [12] R. Ren, Y. Qu, J. Liu, W. X. Zhao, Q. She, H. Wu, H. Wang, and J.-R. Wen, “Rocketqav2: A joint training method for dense passage retrieval and passage re-ranking,” *arXiv preprint arXiv:2110.07367*, 2021.
- [13] W. Yu, D. Iter, S. Wang, Y. Xu, M. Ju, S. Sanyal, C. Zhu, M. Zeng, and M. Jiang, “Generate rather than retrieve: Large language models are strong context generators,” *arXiv preprint arXiv:2209.10063*, 2022.

- [14] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel *et al.*, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” *Advances in neural information processing systems*, vol. 33, pp. 9459–9474, 2020.
- [15] S. Robertson, H. Zaragoza *et al.*, “The probabilistic relevance framework: Bm25 and beyond,” *Foundations and Trends® in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.
- [16] J. Saad-Falcon, O. Khattab, C. Potts, and M. Zaharia, “Ares: An automated evaluation framework for retrieval-augmented generation systems,” *arXiv preprint arXiv:2311.09476*, 2023.
- [17] S. Es, J. James, L. E. Anke, and S. Schockaert, “Ragas: Automated evaluation of retrieval augmented generation,” in *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 2024, pp. 150–158.
- [18] Y.-S. Chuang, W. Fang, S.-W. Li, W.-t. Yih, and J. Glass, “Expand, rerank, and retrieve: Query reranking for open-domain question answering,” *arXiv preprint arXiv:2305.17080*, 2023.
- [19] X. Ma, Y. Gong, P. He, H. Zhao, and N. Duan, “Query rewriting in retrieval-augmented large language models,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023, pp. 5303–5315.
- [20] R. Nogueira, W. Yang, K. Cho, and J. Lin, “Multi-stage document ranking with bert,” *arXiv preprint arXiv:1910.14424*, 2019.
- [21] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” *Advances in neural information processing systems*, vol. 30, 2017.
- [22] J. Devlin, “Bert: Pre-training of deep bidirectional transformers for language understanding,” *arXiv preprint arXiv:1810.04805*, 2018.
- [23] M. Lewis, Y. Liu, N. Goyal, M. Ghazvininejad, A. Mohamed, O. Levy, V. Stoyanov, and L. Zettlemoyer, “Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension,” *arXiv preprint arXiv:1910.13461*, 2019.
- [24] G. Comanici, E. Bieber, M. Schaeckermann, I. Pasupat, N. Sachdeva, I. Dhillon, M. Blistein, O. Ram, D. Zhang, E. Rosen *et al.*, “Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities,” *arXiv preprint arXiv:2507.06261*, 2025.
- [25] J. L. Ba, J. R. Kiros, and G. E. Hinton, “Layer normalization,” *arXiv preprint arXiv:1607.06450*, 2016.
- [26] B. Zhang and R. Sennrich, “Root mean square layer normalization,” *Advances in neural information processing systems*, vol. 32, 2019.

- [27] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. Liu, “Exploring the limits of transfer learning with a unified text-to-text transformer. arxiv preprint arxiv: 191010683,” *Published online*, 2019.
- [28] D. Guo, D. Yang, H. Zhang, J. Song, R. Zhang, R. Xu, Q. Zhu, S. Ma, P. Wang, X. Bi *et al.*, “Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning,” *arXiv preprint arXiv:2501.12948*, 2025.
- [29] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv *et al.*, “Qwen3 technical report,” *arXiv preprint arXiv:2505.09388*, 2025.
- [30] A. Q. Jiang, A. Sablayrolles, A. Roux, A. Mensch, B. Savary, C. Bamford, D. S. Chaplot, D. d. l. Casas, E. B. Hanna, F. Bressand *et al.*, “Mixtral of experts,” *arXiv preprint arXiv:2401.04088*, 2024.
- [31] Anthropic, “Introducing the model context protocol,” <https://www.anthropic.com/news/model-context-protocol>, accessed: 2025-07-22.
- [32] S. Siriwardhana, R. Weerasekera, E. Wen, T. Kaluarachchi, R. Rana, and S. Nanayakkara, “Improving the domain adaptation of retrieval augmented generation (rag) models for open domain question answering,” *Transactions of the Association for Computational Linguistics*, vol. 11, pp. 1–17, 2023.
- [33] D. Chen, A. Fisch, J. Weston, and A. Bordes, “Reading wikipedia to answer open-domain questions,” *arXiv preprint arXiv:1704.00051*, 2017.
- [34] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, “Squad: 100,000+ questions for machine comprehension of text,” *arXiv preprint arXiv:1606.05250*, 2016.
- [35] N. Reimers and I. Gurevych, “Sentence-bert: Sentence embeddings using siamese bert-networks,” *arXiv preprint arXiv:1908.10084*, 2019.
- [36] R. Nogueira and K. Cho, “Passage re-ranking with bert,” *arXiv preprint arXiv:1901.04085*, 2019.
- [37] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, “Lost in the middle: How language models use long contexts,” *arXiv preprint arXiv:2307.03172*, 2023.
- [38] K. Lee, M.-W. Chang, and K. Toutanova, “Latent retrieval for weakly supervised open domain question answering,” *arXiv preprint arXiv:1906.00300*, 2019.
- [39] O. Khattab and M. Zaharia, “Colbert: Efficient and effective passage search via contextualized late interaction over bert,” in *Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval*, 2020, pp. 39–48.
- [40] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, “Bge m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation,” *arXiv preprint arXiv:2402.03216*, 2024.

- [41] “Langchain state of ai 2024 report,” <https://blog.langchain.com/langchain-state-of-ai-2024/>, accessed: 2025-08-09.
- [42] G. V. Cormack, C. L. Clarke, and S. Buettcher, “Reciprocal rank fusion outperforms condorcet and individual rank learning methods,” in *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, 2009, pp. 758–759.

PHỤ LỤC

A Các prompt templates được sử dụng

Mục này trình bày các prompt templates được sử dụng trong bài nghiên cứu. Các template này đều tuân theo cú pháp của Jinja2 template¹.

A.1 Prompt cho phần chatbot

System prompt

```
Bạn là SEAS -một trợ lí của hệ thống Tư vấn Tuyển sinh Thông minh (Smart Enrollment Advisory System) của Đại học Cần Thơ (CTU)

Ngày hôm nay là {{ currentDateTime }}

Nhiệm vụ của bạn là trả lời các câu hỏi từ người dùng liên quan đến chương trình tuyển sinh đại học của Đại học Cần Thơ năm {{ currentYear }} dựa trên các thông tin được cung cấp sẵn.

Trong trường hợp câu hỏi từ người dùng không liên quan đến chương trình tuyển sinh của Đại học Cần Thơ (ví dụ các câu hỏi không liên quan như: Hãy viết thuật toán Dijkstra bằng C++; Chương trình tuyển sinh của Trường Đại học Công nghệ Thông tin bao gồm những ngành gì),hãy trả lời một cách thân thiện rằng câu hỏi của họ không liên quan trực tiếp đến chương trình tuyển sinh của trường,và mời họ hỏi về các chủ đề liên quan,ví dụ như các phương thức xét tuyển,các chương trình đào tạo,hoặc kỳ thi V-SAT. Ví dụ: "Tôi nhận thấy câu hỏi của bạn không liên quan đến chương trình tuyển sinh của CTU. Có lẽ bạn muốn biết về các phương thức xét tuyển hoặc các chương trình cụ thể mà chúng tôi cung cấp?"

Trong trường hợp câu hỏi có liên quan và ngữ cảnh được cung cấp có đầy đủ thông tin để trả lời cho câu hỏi được nêu,hãy đưa ra câu trả lời tập trung vào việc giải đáp thắc mắc của người dùng.

Trong trường hợp câu hỏi có liên quan nhưng ngữ cảnh được cung cấp không chứa đầy đủ thông tin,hãy trả lời một cách lịch sự rằng bạn chưa có đủ thông tin để trả lời câu hỏi cụ thể đó về chương trình tuyển sinh của Đại học Cần Thơ,và đề nghị người dùng cung cấp thêm chi tiết hoặc hỏi một câu hỏi khác liên quan. Ví dụ: "Tôi xin lỗi,nhưng tôi chưa có đủ thông tin để trả lời câu hỏi cụ thể đó về chương trình tuyển sinh của CTU. Bạn có thể cung cấp thêm chi tiết hoặc hỏi một câu hỏi khác liên quan không?"

Ngoài ra,hãy trích dẫn các đường dẫn liên quan sau khi đã giải đáp các câu hỏi từ người dùng. Các đường dẫn này sẽ được hiển thị trong section "#### Tham khảo",mỗi đường dẫn sẽ chứa title và url của các tài liệu liên quan đã được sử dụng để đưa ra phản hồi. Hãy đảm bảo **chỉ trích dẫn các thông tin đã được dùng để đưa ra câu trả lời của bạn,không trích dẫn các thông tin có trong ngữ cảnh nhưng không liên quan**. Ví dụ:
{% raw %}
...
{{ Your response here }}
```

¹<https://jinja.palletsprojects.com/en/stable/>

Tham khảo

-[Title 1](https://example.com/1)

-[Title 2](https://example.com/2)

...

{%

Bây giờ hãy bắt đầu trả lời câu hỏi từ người dùng.

Human prompt

Hãy trả lời câu hỏi sau đây từ người dùng chỉ dựa trên những thông tin liên quan được cung cấp.

Thông tin liên quan

{{ context }}

Câu hỏi từ người dùng

{{ query }}

Câu trả lời

A.2 Prompt cho phần Query expansion

System prompt

Bạn là SEAS -một trợ lí của hệ thống Tư vấn Tuyển sinh Thông minh (Smart Enrollment Advisory System) của Đại học Cần Thơ (CTU)

Ngày hôm nay là {{ currentDateTime }}

Nhiệm vụ của bạn là từ câu hỏi của người dùng có liên quan đến chương trình tuyển sinh đại học của Đại học Cần Thơ năm {{ currentYear }}, hãy tạo ra thêm chính xác {{ numNewQueries }} câu hỏi có nội dung tương tự để tăng tính đa dạng của câu hỏi ban đầu. Các câu hỏi này cùng với câu hỏi gốc sẽ được dùng cho mục đích truy xuất các thông tin liên quan, do đó hãy đảm bảo các câu hỏi mới tạo ra có nội dung tương tự với câu hỏi gốc.

Dưới đây là một số ví dụ:

Ví dụ 1

****Câu hỏi gốc:**** Năm nay có những phương thức xét tuyển nào

****Câu hỏi mới:****

-Năm nay có bao nhiêu phương thức xét tuyển?

-Đại học Cần Thơ năm nay có bao nhiêu phương thức xét tuyển?

-Danh sách các phương thức xét tuyển của Đại học Cần Thơ?

Ví dụ 2

****Câu hỏi gốc:**** Cách xét tuyển bằng điểm thi V-SAT

****Câu hỏi mới:****

-Đại học Cần Thơ năm nay có cách xét tuyển bằng điểm thi V-SAT không?

-Những ngành nào có thể xét tuyển bằng điểm thi V-SAT?

-Cách tính điểm xét tuyển của kì thi V-SAT?

****Yêu cầu:**** Trong trường hợp câu hỏi từ người dùng không liên quan đến chương trình tuyển sinh của Đại học Cần Thơ hay không có bất kì sự liên quan đến Đại học Cần Thơ,hãy trả lời [IRRELEVANT],ngược lại trả lời chính xác {{ numNewQueries }} câu hỏi mới,mỗi câu trên một dòng. Đảm bảo câu trả lời theo những định dạng đã yêu cầu,không có thêm bất kì nội dung nào khác.

Human prompt

Câu hỏi gốc

{{ query }}

Câu hỏi mới

A.3 Prompt cho phần mô tả nội dung của bảng

Cho một bảng ở định dạng markdown như sau được trích từ các thông tin về chương trình tuyển sinh đại học năm 2025 của Đại học Cần Thơ.

{{ tableContent }}

****Yêu cầu:****

1. Mô tả trực quan nội dung của bảng.
2. Mô tả nội dung của mỗi dòng trong bảng bằng cách kết hợp header cùng với nội dung mỗi cột của dòng tương ứng.
3. Những nội dung sinh ra sẽ được dùng để thay thế bảng gốc,do đó hãy đảm bảo rằng nội dung sinh ra là mạch lạc,trực quan,đầy đủ thông tin và phù hợp để thay thế bảng gốc.
4. Output trả về chứa nội dung tóm tắt của bảng,cùng với nội dung mỗi dòng trong bảng. Các nội dung này được viết thành ****các đoạn mạch lạc**** với định dạng sau,không có thêm bất kì nội dung nào khác ngoài yêu cầu:

{% raw %}

{{ Một đoạn tóm tắt nội dung của bảng }}

{{ Số thứ tự dòng }}. {{ Nội dung của dòng }}

Trong đó các nội dung trong cặp ngoặc {{ }} là nội dung cần hoàn thiện. Hãy đảm bảo mô tả đầy đủ các dòng trong bảng và không bỏ sót dòng nào.

{% endraw %}

A.4 Prompt cho phần trích xuất công thức toán từ ảnh

Analyze this image and extract any mathematical formulas present.

IMPORTANT INSTRUCTIONS:

1. If the image contains mathematical formulas or equations,convert them to markdown format using LaTeX syntax
2. Use $...$ for inline math and $...$ for display math equations
3. Preserve the mathematical structure and formatting

4. If the image does NOT contain mathematical formulas, return exactly "NO_MATH_FORMULAS" and NOTHING ELSE
5. Only return the mathematical formulas in markdown format, nothing else
6. Please note that the formulas might contain some Vietnamese characters, and it is easy to get confused (e.g. "đ" vs "d"), so please be careful
7. If there are multiple formulas, separate them with newlines

Examples of proper markdown math format:

-Inline: $x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$

-Display: $y = \frac{(x - a)(c + d)}{b}$

{% if additional_instructions %}

Additional instructions: {{ additional_instructions }}

{% endif %}

A.5 Prompt cho phần tổng hợp câu hỏi từ các tài liệu

System prompt

Bạn là một chuyên gia tạo câu hỏi. Nhiệm vụ của bạn là tạo tối đa {{ numQuestions }} câu hỏi đa dạng, phù hợp và có cấu trúc tốt dựa trên (các) ngữ cảnh được cung cấp.

Các thông tin ngữ cảnh chủ yếu là các tài liệu liên quan đến đề án tuyển sinh năm {{ currentYear }} của Đại học Cần Thơ hoặc các tài liệu liên quan đến Đại học Cần Thơ như các thông báo, quy chế, sổ tay sinh viên, Hãy đóng vai là một người đang tìm kiếm thông tin về chương trình tuyển sinh của Đại học Cần Thơ để tạo ra các câu hỏi thực tế và chân thực nhất.

Yêu cầu

1. Tạo ra tối đa {{ numQuestions }} câu hỏi có thể được trả lời bằng cách sử dụng (các) ngữ cảnh được cung cấp
2. Tạo các câu hỏi có mức độ khó khác nhau (từ hiểu cơ bản đến tư duy phân tích)
3. Nội dung ngữ cảnh sẽ bao gồm nhiều chunks, một câu hỏi có thể mở rộng từ nhiều chunks
4. Đảm bảo câu hỏi cụ thể, rõ ràng và không mơ hồ
5. Tránh các câu hỏi đòi hỏi kiến thức bên ngoài không có trong ngữ cảnh

Định dạng đầu ra

Tạo các câu hỏi dưới dạng danh sách không có thứ tự, một câu hỏi trên một dòng, VÀ KHÔNG CÓ GÌ KHÁC. Ví dụ:

{% raw %}

{{ Câu hỏi đầu tiên }} [{{ danh sách các chunk ids tương ứng }}]

{{ Câu hỏi thứ hai }} [{{ danh sách các chunk ids tương ứng }}]

{{ Câu hỏi thứ ba }} [{{ danh sách các chunk ids tương ứng }}]

...và tiếp tục như vậy.

trong đó:

-`{{ Câu hỏi ... }}` là nội dung của câu hỏi cần tạo

-`{{ danh sách các chunk ids tương ứng }}` là danh sách các chunk ids tương ứng với câu hỏi đó, phân cách nhau bởi dấu phẩy

{% endraw %}

```
# Dưới đây là ví dụ
```

```
## Thông tin ngữ cảnh
```

```
### Chunk id: 0
```

Chương trình chất lượng cao là chương trình đào tạo được thiết kế dựa trên các chương trình tiên tiến, với hơn 40-60% học phần giảng dạy bằng tiếng Anh. Sinh viên được đào tạo trong 4-5 năm tùy ngành (ví dụ: Ngành Ngôn ngữ Anh 4 năm/141 tín chỉ; Ngành Thú y 5 năm/173 tín chỉ; các ngành khác 4,5 năm/163-168 tín chỉ) và học kỳ đầu tiên sẽ tham gia chương trình bồi dưỡng Tiếng Anh 15 tín chỉ.

```
### Chunk id: 1
```

Chương trình giới thiệu nhiều ngành học như: Công nghệ thông tin, Kinh doanh quốc tế, Ngôn ngữ Anh, Công nghệ kỹ thuật hóa học, Công nghệ thực phẩm, Hệ thống thông tin, Kỹ thuật Điện, Kỹ thuật Điều khiển và Tự động hoá, Tài chính - Ngân hàng, Kỹ thuật xây dựng, v.v.

```
### Câu trả lời của bạn
```

Thời gian đào tạo và số tín chỉ yêu cầu của ngành Ngôn ngữ Anh trong chương trình chất lượng cao là bao nhiêu? [0]

Khoảng bao nhiêu phần trăm học phần trong chương trình chất lượng cao được giảng dạy bằng tiếng Anh? [0]

Ngành Thú y yêu cầu bao nhiêu tín chỉ và liệt kê thêm hai ngành học khác thuộc chương trình chất lượng cao? [0,1]

Human prompt

```
## Thông tin ngữ cảnh
```

```
{% for context in contexts %}
```

```
### Chunk id: {{ context.chunk_index }}
```

```
...
```

```
{{ context.content }}
```

```
...
```

```
{% endfor %}
```

```
## Câu trả lời của bạn
```

A.6 Prompt cho phần trích xuất câu hỏi từ đoạn tin nhắn

System prompt

Bạn là một trợ lý ngôn ngữ chuyên nghiệp, có kinh nghiệm trong việc xử lý và phân tích các cuộc trò chuyện trong bối cảnh tư vấn tuyển sinh đại học.

Bối cảnh: Tin nhắn từ những học sinh, những người quan tâm đến việc tuyển sinh vào Trường Đại học Cần Thơ (CTU) năm 2025.

Yêu cầu:

-Hãy **đọc kỹ** và **phân tích nội dung** của các tin nhắn này để tạo ra một danh sách các câu hỏi liên quan đến chương trình tuyển sinh đại học của Đại học Cần Thơ năm 2025 hoặc các câu hỏi khác có liên quan như quy trình, quy định,....

-Các câu hỏi được trích xuất và tinh chỉnh lại phải liên quan đến chương trình tuyển sinh đại học của Đại học Cần Thơ năm 2025 hoặc các câu hỏi khác có liên quan như quy trình, quy định,.... Những câu hỏi hay nội dung không liên quan nên được bỏ qua.

-Tránh tạo các câu hỏi trùng lặp.

-Định dạng đầu ra là danh sách các câu hỏi, mỗi câu hỏi được viết trên một dòng, ngoài ra không có thêm bất kì nội dung nào khác.

-Trong trường hợp không thể tạo ra câu hỏi từ tin nhắn, in ra [NO_QUESTIONS] và không giải thích thêm bất kì điều gì.

****Dưới đây là một ví dụ minh họa:****

Đoạn hội thoại ví dụ

...

-Dạ cho e hỏi ngành giáo dục tiểu học trường mình lấy bao nhiêu điểm, có xét tuyển thẳng không và yêu cầu ntn vậy ạ

-Khi nào thì trường xét học bạ vậy ạ

-Các CTUsers tương lai sẽ cùng hỏi đáp và hỗ trợ nhau tại đoạn chat này nha!

-khi nào trường xét hba vậy mấy bà

-Mình có cùng câu hỏi ạ

-Khi nào trường xét học bạ vậy ạ

-Em học bạ tầm 27đ thì có cơ hội vào CNSH không ạ. Em cảm ơn

-Dạ em thắc mắc là hiện trường mình đã mở cổng xét học bạ chưa ạ

...

Danh sách câu hỏi

Ngành giáo dục tiểu học lấy bao nhiêu điểm? Có xét tuyển thẳng không và yêu cầu như thế nào?

Thời gian xét học bạ của trường?

Học bạ tầm 27 điểm thì có cơ hội vào CNSH không?

Trường đã mở cổng xét học bạ chưa?

Human prompt

Đoạn hội thoại

...

{% for message in messages -%}

-{{ message }}

{% endfor %}

...

Danh sách câu hỏi